



Universidad de las Américas Puebla

Licenciatura en Actuaría

Proyecto RLM

Materia: Econometría I

Profesor(a): Daniela Cortés Toto

Autores:

Karla Yunuen Fischer Juárez
Claudia Verónica Montes Armas
Shaiel Benet Morales Fortozo

Puebla, México
30 de marzo de 2026

Índice

1. Introducción	2
1.1. Elección de variables y preparación de la base de datos	2
2. Modelo Original	3
2.1. Selección de los mejores modelos	3
2.2. Interpretación de los modelos	6
2.3. Validación de los modelos	8
2.4. Propuesta y justificación de los mejores modelos	13
3. Modelo Log-Log	13
3.1. Selección de los mejores modelos	13
3.2. Interpretación de los modelos	17
3.3. Validación de los modelos	19
3.4. Propuesta y justificación de los mejores modelos	24
4. Modelo Log-Lin	24
4.1. Selección de los mejores modelos	24
4.2. Interpretación de los modelos	26
4.3. Validación de los modelos	27
4.4. Propuesta y justificación de los mejores modelos	32
5. Modelo estandarizado	32
5.1. Selección de los mejores modelos	32
5.2. Interpretación de los modelos	34
5.3. Validación de los modelos	36
5.4. Propuesta y justificación de los mejores modelos	39
6. Conclusiones	40

1. Introducción

El turismo, que forma parte de las economías de servicios, representa una gran fuente de ingresos a nivel mundial, una de la más importantes ya que aporta de gran manera al crecimiento económico, generación de empleos y captación de divisas. México es una economía fuerte en orientación hacia las economías de servicios y seguirá evolucionando, sin embargo, no se trata de un sector aislado, sino que surge como resultado de una interacción y combinación de actividades, servicios e industrias. Entender todo este conjunto, junto a los factores determinantes permitirán que los sectores privado y público tomen decisiones informadas y que beneficien al consumidor.

Por ello, en el siguiente reporte se busca analizar aquellos factores que se consideran importantes en su comportamiento y cambio, con un análisis de Regresión Lineal Múltiple, que nos permite hacer uso de más de una variable explicativa, y los factores asociados a la productividad de servicios terciarios, cambio en los precios al consumidor e inflación. Para este estudio, se plantea la hipótesis de que, en México, el turismo depende principalmente de la situación económica general y del costo de vida. Se espera que las variables que tengan un impacto positivo en el turismo, sean el Índice de precios al Consumidor y el Gasto en Hotelería, mientras que el Personal ocupado en comercio minorista y el Personal ocupado en hoteles impacten de manera negativa, ya que al subir los costos, debería disminuir la demanda. De esta manera, se facilitará observar el efecto y peso de cada factor en la variable dependiente.

1.1. Elección de variables y preparación de la base de datos

La selección de variables constituye una etapa fundamental en la construcción de un modelo de regresión lineal múltiple, ya que determina la capacidad explicativa del modelo y la validez de los resultados obtenidos. En este estudio, se consideró un conjunto de variables macro-económicas relevantes como posibles regresoras: el Índice de Precios al Consumidor (*IPC*), Precios Hoteleros (*PH*), Gasto en Hospedaje (*GH*), Personal en el comercio minorista (*PC*), Costo unitario de mano de obra (*CL*) y la Producción Industrial (*PROD*).

Por lo cual el modelo general planteado puede expresarse como:

$$Y_i = \beta_0 + \beta_1 IPC + \beta_2 PH + \beta_3 GH + \beta_4 PC + \beta_5 PROD + \beta_6 CL + \beta_7 INF_i + \epsilon \quad (1)$$

Donde Y_i representa el consumo privado turístico interior en el periodo i . β_0 es el intercepto. Y β_j son los coeficientes asociados a cada variable explicativa y ϵ representa el término de error.

Previo a la estimación del modelo, se realizó un proceso de depuración de la base de datos. Este proceso incluyó la verificación de valores faltantes, detección de posibles valores atípicos y revisión de consistencia en las observaciones. Asimismo, se aseguró que todas las variables estuvieran expresadas en la misma frecuencia temporal, con el fin de garantizar la compatibilidad entre ellas.

Posteriormente, se llevó a cabo la verificación del supuesto de multicolinealidad, mediante el Factor de Inflación de la Varianza (VIF), el cual mide cuánto aumenta la varianza de un coeficiente de regresión

estimado debido a las dependencias lineales entre las variables regresoras, mediante la siguiente formula:

$$VIF_j = \frac{1}{1 - R_j^2} \quad (2)$$

Donde R_j^2 es el coeficiente de determinación múltiple que se obtiene al realizar una regresión de la variable x_j con respecto a todas las demás variables regresoras del modelo. Un VIF cercano a 1 indica que la variable es casi ortogonal a las demás regresoras. (no esta correlacionada)

Si tenemos $1 < VIF \leq 5$, se considera una correlación moderada, por lo cuál no es necesario corregirla. Por otra parte si el $VIF > 5$, se sugieren niveles críticos de multicolinealidad, lo cuál indica una poca estabilidad de las estimaciones del modelo y será necesario corregirla.

```
> vif(regresion_original)
```

IPC	PH	GH	PC	IGAE	PROD	CL	INF
10.737955	6.354769	15.273797	6.454795	9.374041	6.341768	2.482579	1.234534

Como podemos observar no cumple con el supuesto de multicolinealidad, ya que muchas variables son mayores a 5, por lo que más adelante se corregirá el supuesto en los diferentes modelos propuestos. El análisis de correlación es fundamental para detectar la presencia de multicolinealidad entre las variables explicativas. En términos formales, existe multicolinealidad cuando una variable explicativa puede expresarse como una combinación lineal de otras.




Figura 1: Gráfica de correlación de las variables respuesta.

2. Modelo Original

2.1. Selección de los mejores modelos

Para poder identificar la especificación más adecuada del modelo, se utilizaron dos metodologías de selección: Comando stepwise y el comando regsubsets.

1. Comando step: Enfoque iterativo que añade variables, elimina variables o ambas. Este algoritmo selecciona el modelo óptimo, evaluando la contribución de cada variable, basándose en el Criterio

de Información de Akaike, el cual es una medida estadística que se utiliza para comparar modelos y elegir el que mejor equilibra el ajuste del modelo a los datos y la complejidad del modelo. El AIC se puede calcular como:

$$AIC = -1 \ln(L) + 2k \quad (3)$$

Donde, L es la verosimilitud del modelo y k el número de parámetros del modelo. Al aplicar la especificación del modelo AIC se obtuvo lo siguiente:

Call:

```
lm(formula = TUR ~ IPC + PH + GH + PC + CL, data = Turismo)
```

Esto nos quiere decir que el modelo puede plantear de la siguiente forma:

$$TUR = \beta_0 + \beta_1 IPC + \beta_2 PH + \beta_3 GH + \beta_4 PC + \beta_5 CL + \epsilon \quad (4)$$

Al aplicar el summary al modelo AIC se obtuvieron los siguientes resultados:

```
> summary(regresion_step)
```

Call:

```
lm(formula = TUR ~ IPC + PH + GH + PC + CL, data = Turismo)
```

Residuals:

Min	1Q	Median	3Q	Max
-6.3852	-1.2633	-0.0459	1.4320	3.7486

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	117.94798	8.41490	14.017	< 2e-16 ***
IPC	0.33679	0.01844	18.268	< 2e-16 ***
PH	-0.16169	0.07916	-2.043	0.0452 *
GH	0.36698	0.04396	8.347	7.06e-12 ***
PC	-0.81781	0.13174	-6.208	4.24e-08 ***
CL	0.06479	0.03189	2.032	0.0463 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.273 on 65 degrees of freedom

Multiple R-squared: 0.9242, Adjusted R-squared: 0.9184

F-statistic: 158.6 on 5 and 65 DF, p-value: < 2.2e-16.

En donde el modelo es globalmente significativo, lo cual implica que el conjunto de variables explica de manera importante la variabilidad de *TUR*.

Multicolinealidad: Por medio del $VIF_j = \frac{1}{1-R_j^2}$, se obtuvo lo siguiente:

```
> vif(regresion_step)
      IPC      PH      GH      PC      CL
2.220394 5.205880 4.670420 2.648294 2.240820
```

Como todos los valores $VIF > 5$ implica que hay multicolinealidad.

2. Comando `regsubsets`: Búsqueda de los mejores subconjuntos, donde se comparan todas las combinaciones posibles de variables con modelos de diferentes tamaños donde se permite la comparación de métricas como el R^2 ajustado, el Cp de Mallows o el BIC. El modelo BIC es otro criterio para la selección del mejor modelo estadístico, el cuál es más estricto con la cantidad de variables. BIC se puede calcular de la siguiente manera:

$$BIC = -2\ln(L) + k\ln(n) \quad (5)$$

En donde, L es la verosimilitud del modelo, k es el número de parámetros y n es el tamaño de la muestra. La principal diferencia con AIC, es la penalización, BIC penaliza más fuertemente el número de variables debido a que utiliza $\ln(n)$ en lugar de 2. Al aplicar la especificación del modelo BIC se obtuvo lo siguiente:

(Intercept)	IPC	PH	GH	PC
TRUE	TRUE	FALSE	TRUE	TRUE
PROD	CL	INF		
FALSE	FALSE	FALSE		

Esto nos quiere decir que el modelo puede plantear de la siguiente forma:

$$TUR = \beta_0 + \beta_1 IPC + \beta_2 GH + \beta_3 PC + \epsilon \quad (6)$$

Al aplicar el `summary` al modelo BIC obtuvimos lo siguiente:

```
> summary(modelo_BIC)
Call:
lm(formula = TUR ~ IPC + GH + PC, data = Turismo)
Residuals:
      Min       1Q   Median       3Q      Max
-7.2366 -1.3450  0.2544  1.5229  3.7963
Coefficients:
      Estimate Std. Error t value Pr(>|t|)
            1
```

```

(Intercept) 119.22005    8.73040   13.656   < 2e-16 ***
IPC          0.35689    0.01381   25.844   < 2e-16 ***
GH           0.26040    0.02334   11.157   < 2e-16 ***
PC          -0.83050    0.09750   -8.518  2.81e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Residual standard error: 2.373 on 67 degrees of freedom
Multiple R-squared: 0.915, Adjusted R-squared: 0.9111
F-statistic: 240.3 on 3 and 67 DF, p-value: < 2.2e-16

Multicolinealidad: Por medio del $VIF_j = \frac{1}{1-R_j^2}$, se obtuvo lo siguiente:

```

> vif(modelo_limpio_BIC)
      IPC      GH      PC
1.182358 1.263955 1.450587

```

Como todos los valores $VIF < 5$ implica que no hay multicolinealidad.

El modelo AIC no cumple con el supuesto de multicolinealidad. Por el contrario, el modelo seleccionado por BIC si cumple con dicho supuesto.

Dado que la validez de la inferencia estadística depende del cumplimiento de los supuestos del modelo de regresión, se selecciona el modelo BIC como el modelo final.

2.2. Interpretación de los modelos

El modelo quedó de la siguiente manera:

$$TUR = 119.220 + 0.35689IPC + 0.26040GH - 0.83050PC \quad (7)$$

El ANOVA del modelo BIC se obtuvo lo siguiente:

```

> anova(modelo_BIC)
Analysis of Variance Table

Response: TUR
      Df Sum Sq Mean Sq F value    Pr(>F)
IPC     1 3253.0   3253.0  577.882 < 2.2e-16 ***
GH      1  396.0    396.0   70.342 4.829e-12 ***
PC      1  408.4    408.4   72.549 2.811e-12 ***
Residuals 67  377.2      5.6
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Por lo cual se concluye que *IPC*: altamente significativa, *GH*: altamente significativa y *PC*: altamente significativa. El ANOVA confirma que todas las variables incluidas aportan significativamente al modelo.

Interpretación de los coeficientes de regresión: El intercepto ($\beta_0 = 119.22005$), representa el valor esperado de *TUR* cuando las variables explicativas son cero. Aunque no tiene interpretación económica directa, sirve como punto base del modelo.

IPC ($\beta_1 = 0.35689$), manteniendo constantes *GH* y *PC*, un incremento de una unidad en *IPC* aumenta el turismo en aproximadamente 0.35689 unidades. El *IPC* tiene un efecto positivo significativo sobre el turismo, lo que sugiere que mayor dinamismo económico está asociado con mayor actividad turística.

GH ($\beta_2 = 0.26040$), manteniendo constantes *IPC* y *PC*, un aumento de una unidad en *GH* incrementa el turismo en 0.26040 unidades. El turismo es un bien normal o en algunas ocasiones de lujo, cuando los hogares gastan más, tienen mayor capacidad para viajar.

PC ($\beta_3 = -0.8305$), manteniendo constantes *GH* y *IPC*, un aumento de una unidad en *PC* reduce el turismo en aproximadamente 0.8305 unidades. Si las personas se encuentran ocupadas en el comercio minorista, se reduce la demanda turística, el turismo es sensible a precios (elasticidad negativa). Se confirma una relación inversa entre costos y turismo.

Interpretación de las pruebas de significancia:

Se evalúa:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0 \quad (8)$$

Variable	t value	p-value	Conclusión
Intercepto	13.656	$< 2e - 16$	Significativo
<i>IPC</i>	25.844	$< 2e - 16$	Significativo
<i>GH</i>	11.157	$< 2e - 16$	Significativo
<i>PC</i>	-8.518	$2.81e - 12$	Significativo

Cuadro 1: Resultados de pruebas de significancia de los parámetros

Todas las variables son estadísticamente significativas, con $p < 0.05$. Por lo cual, se rechaza H_0 .

Interpretación de la significancia global del modelo (Prueba F):

Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \quad \text{vs} \quad H_1 : \text{al menos uno es diferente de } 0 \quad (9)$$

Se obtuvo el siguiente resultado: $F = 240.3$ y $p < 2.2 \times 10^{-16}$.

El modelo es globalmente significativo y como $p < 0.05$ se rechaza H_0 . El coeficiente de determinación $R^2 = 0.915$ eso nos dice que el 91.5% de la variabilidad de *TUR* es explicada por *IPC*, *GH* Y *PC*. El $R^2_{ajustado} = 0.9111$, lo cual indica un buen ajuste incluso penalizando por número las variables. El error estándar residual $\sigma = 2.373$, nos dice que en promedio, el modelo se equivoca

± 2.373 unidades en *TUR*.

Intervalos de respuesta media y predicción:

Para el intervalo de respuesta media, tenemos el valor estimado $\hat{Y} = 94.43$ y el intervalo al 95 % = [93.04, 95.82].

Este intervalo indica que, para los valores específicos de las variables explicativas considerados, el valor promedio esperado del turismo se encuentra entre 93.04 y 95.82, con el nivel de confianza 95 %. Bajo las condiciones económicas dadas (niveles de precios, gasto, costos, etc.), se espera que el turismo promedio se sitúe alrededor de 94.43 unidades, con poca variabilidad en su valor medio.

Intervalo de predicción, tenemos el valor estimado, $\hat{Y} = 94.43$ y el intervalo [89.50, 99.37]. Este intervalo indica que una observación individual futura del turismo, bajo las mismas condiciones, puede tomar valores entre 89.50 y 99.37, y con un 95 % de confianza. El intervalo de predicción es más amplio porque incluye, la variabilidad del modelo y la variabilidad individual.

2.3. Validación de los modelos

Identificación de valores atípicos: Se utilizaron residuos estudentizados:

$$t_i = \frac{e_i}{\hat{\sigma}_{(i)} \sqrt{1 - h_{ii}}} \quad (10)$$

Y se comparo con:

$$t_{\alpha/2, n-k-2} \quad (11)$$

Donde, si $t_i > t_{\alpha/2}$ es una observación atípica, lo cual quiere decir que el error de esa observación es demasiado grande comparado al resto. En este caso $\alpha = 0,05$ y $t_{\alpha/2} = 1,997$, como resultado se identificaron como valores atípicos las observaciones.

```
> atipicos2
5  9 59
```

Estas observaciones presentan residuales significativamente grandes, lo que indica que; el modelo no las explica adecuadamente y pueden distorsionar la estimación de parámetros.

Detección de puntos de apalancamiento: Se analizaron los valores de leverage:

$$h_i = X(X'X)^{-1}X' \quad (12)$$

Y se utilizó el siguiente criterio:

$$h_i > \frac{3(k+1)}{n} \quad (13)$$

Como resultado se detecto como punto de apalancamiento:

Distancia de Cook:

$$D_i(\mathbf{M}, c) = \frac{(\beta_{(i)} - \hat{\beta})' \mathbf{M} (\beta_{(i)} - \hat{\beta})}{c}, \quad i = 1, 2, \dots, n \quad (14)$$

Donde si $D_i > 1$ se consideran influyentes los puntos. En este caso no hay ningún valor tal que $D_i > 1$, por lo que no hay observaciones altamente influyentes.

Eliminación de observaciones: Se decidió eliminar los valores atípicos: 5, 9, 59 y el punto de apalancamiento 50. Por lo tanto las observaciones eliminadas son las siguientes 5, 9, 59, 50. Se decidió ya que los atípicos afectan la normalidad y varianza, el punto de apalancamiento puede sesgar la regresión, aunque Cook no es alto, la combinación justifica su eliminación.

Por lo cual después de eliminar valores atípicos el modelo quedó de la siguiente manera:

$$TUR = 115.08823 + 0.34666IPC + 0.27694GH - 0.79179PC \quad (15)$$

Verificación de supuestos:

a) Homocedasticidad (Breush-Pagan): Tenemos las siguientes hipótesis

$$H_0 : \text{varianza constante} \quad \text{vs} \quad H_1 : \text{Heterocedasticidad} \quad (16)$$

Se obtuvo el siguiente resultado:

```
> bptest(modelo_limpio_BIC)
studentized Breusch-Pagan test
data:  modelo_limpio_BIC
BP = 1.4916, df = 3, p-value = 0.6842
```

Como el $p > 0.05$ no se rechaza H_0 . Por lo cual, concluimos que se cumple homocedasticidad.

b) Independencia (Box-Pierce):

En donde tenemos las siguientes hipótesis

$$H_0 : \text{No autocorrelación} \quad \text{vs} \quad H_1 : \text{Autocorrelación} \quad (17)$$

En este caso se obtuvo el siguiente resultado:

```
> Box.test(residuales_regresion_limpia_BIC, lag=5, type="Box-Pierce")

Box-Pierce test

data:  residuales_regresion_limpia_BIC
```

X-squared = 24, df = 5, p-value = 0.0002171

Como el $p < 0.05$, nos dice que se rechaza H_0 y que si existe autocorrelación en los residuos. Por lo cual, no se cumple el supuesto.

c) Media cero: Se quiere probar que

$$H_0 : E(\epsilon) = 0 \quad \text{vs} \quad H_1 : E(\epsilon) \neq 0 \quad (18)$$

```
> t.test(residuales_regresion_limpia_BIC, alternative= "two.sided", mu=0,
paired= FALSE, conf.level=0.95)
```

One Sample t-test

```
data:  residuales_regresion_limpia_BIC
t = -5.5192e-18, df = 65, p-value = 1
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.4651366  0.4651366
sample estimates:
 mean of x
-1.285437e-18
```

Como el $p > 0.05$, se cumple el supuesto de media cero.

d) Normalidad (Shapiro-Wilk): Se requiere comparar

$$H_0 : \text{Normalidad} \quad \text{vs} \quad H_1 : \text{No normalidad} \quad (19)$$

```
> shapiro.test(residuales_regresion_limpia_BIC)
```

Shapiro-Wilk normality test

```
data:  residuales_regresion_limpia_BIC
W = 0.9722, p-value = 0.1444
```

Como el $p > 0.05$, implica que no se rechaza normalidad.

A continuación se presenta el ANOVA y summary del modelo ganador después del procedimiento de los valores atípicos y apalacamientos.

```
> anova(modelo_limpio_BIC)
Analysis of Variance Table
```

Response: TUR

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
IPC	1	2987.04	2987.04	795.847	< 2.2e-16 ***
GH	1	104.66	104.66	27.885	1.754e-06 ***
PC	1	308.98	308.98	82.323	5.567e-13 ***
Residuals	62	232.70	3.75		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> summary(modelo_limpio_BIC)
```

Call:

```
lm(formula = TUR ~ IPC + GH + PC, data = Turismo_limpio_BIC)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.8753	-1.4512	0.1534	1.2950	3.2931

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	115.08823	7.33407	15.692	< 2e-16 ***
IPC	0.34666	0.01185	29.256	< 2e-16 ***
GH	0.27694	0.03026	9.153	4.06e-13 ***
PC	-0.79179	0.08727	-9.073	5.57e-13 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.937 on 62 degrees of freedom

Multiple R-squared: 0.936, Adjusted R-squared: 0.9329

F-statistic: 302 on 3 and 62 DF, p-value: < 2.2e-16

Se redujo bastante el error estándar. Y aumento un poco la R^2 ajustada, Igualmente podemos observar todas las variables son significativas y hay un mejor cumplimiento de supuestos.

Interpretación de las pruebas de significancia:

Se evalúa:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0 \quad (20)$$

Variable	t value	p-value	Decisión
Intercepto	15.692	$< 2e - 16$	Rechazar H_0 es significativo
<i>IPC</i>	29.256	$< 2e - 16$	Rechazar H_0 es significativo
<i>GH</i>	9.153	$4.06e - 13$	Rechazar H_0 es significativo
<i>PC</i>	-9.073	$5.57e - 13$	Rechazar H_0 es significativo

Cuadro 2: Resultados de pruebas de significancia de los parámetros

Todos los coeficientes tienen p-values extremadamente pequeños ($p < 0.05$). Por lo cual, se rechaza H_0 para todas las variables. Todas las variables incluidas en el modelo son estadística-mente significativas y contribuyen de manera individual a explicar el turismo.

Interpretación de la significancia global del modelo (Prueba F):

Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0 \quad \text{vs} \quad H_1 : \text{al menos uno es diferente de } 0 \quad (21)$$

Se obtuvo el siguiente resultado: $F = 302$ y $p < 2.2 \times 10^{-16}$.

Se rechaza H_0 , por lo que el modelo es globalmente significativo. Es decir, el conjunto de variables explica de manera conjunta el comportamiento del turismo.

Interpretación del ANOVA:

Variable	F value	p-value	Interpretación
<i>IPC</i>	795.847	$< 2.2e - 16$	Mayor Contribución
<i>GH</i>	27.885	$1.754 - 06$	Contribución importante
<i>PC</i>	82.323	$5.567 - 13$	Contribución significativa

Cuadro 3: Interpretación del ANOVA

IPC es la variable más importante del modelo, ya que tiene el mayor F , por lo que explica la mayor parte de la variabilidad del turismo.

Por otra parte, el *GH*, tiene una contribución significativa, ya que aporta información adicional relevante sobre el comportamiento del turismo.

Finalmente, *PC*, también es significativa, afecta significativamente al turismo y su contribución es importante.

Los residuos mostraron una variabilidad no explicada de 232.70 y un error medio de 3.75, esto indica que el modelo logra explicar gran parte de la variabilidad total.

Así mismo, tenemos un $R^2 = 0.936$ y una $R^2_{ajustada} = 0.9329$. Esto nos indica, que el modelo explica aproximadamente el 93.6 % de la variabilidad del turismo, lo cual indica un excelente ajuste.

Intervalos de respuesta media y predicción:

Para el intervalo de respuesta media, tenemos el valor estimado $\hat{Y} = 94.946$ y el intervalo al 95 % = $[93.57, 96.32]$.

Este intervalo indica que, para los valores específicos de las variables explicativas, el valor promedio esperado del turismo se encuentra entre 93.57 y 96.32, con un 95 % de confianza. En otras palabras, el modelo estima con alta precisión el nivel del turismo bajo dichas condiciones económicas.

Intervalo de predicción, tenemos el valor estimado, $\hat{Y} = 94.946$ y el intervalo $[90.84, 99.06]$. Este intervalo indica que una observación individual futura del turismo puede ubicarse entre 90.84 y 99.06, con el nivel de confianza del 95 %. El valor esperado del turismo es aproximadamente 94.95, muy cercano al obtenido antes de eliminar atípicos. El intervalo de la confianza de la media es relativamente estrecho, lo que indica una buena precisión en la estimación.

2.4. Propuesta y justificación de los mejores modelos

Interpretación de los coeficientes de regresión: El intercepto ($\beta_0 = 114.556$), representa el valor esperado de TUR cuando $IPC = GH = PC = 0$. Aunque no tiene interpretación económica directa, sirve como punto base del modelo.

IPC ($\beta_1 = 0.3463$), manteniendo constantes GH y PC , un incremento de una unidad en IPC aumenta el turismo en aproximadamente 0.3463 unidades. El IPC tiene un efecto positivo significativo sobre el turismo, lo que sugiere que mayor dinamismo económico está asociado con mayor actividad turística. Es la variable con mayor contribución según el ANOVA ($F = 782.83$), lo que indica que el dinamismo económico general es el principal motor del turismo en este modelo.

GH ($\beta_2 = 0.2601$), manteniendo constantes IPC y PC , un aumento de una unidad en GH incrementa el turismo en 0.260 unidades. El crecimiento impulsa el turismo, reflejando que mejores condiciones económicas favorecen la demanda turística. Tiene un impacto positivo y estadísticamente significativo ($p < 0.05$), confirmando que a medida que aumenta la capacidad o disposición de gasto en servicios básicos de viaje, el consumo turístico crece.

PC ($\beta_3 = -0.7701$), manteniendo constantes GH y IPC , un aumento de una unidad en PC reduce el turismo en aproximadamente 0.770 unidades. Esta variable tiene el impacto unitario más fuerte, pero en sentido negativo. Esto refleja una alta sensibilidad del sector: el aumento del personal ocupado en el comercio minorista, reduce drásticamente la demanda turística.

3. Modelo Log-Log

3.1. Selección de los mejores modelos

Ya se conoce el modelo de regresión lineal múltiple completo, dado que la variable INF contiene valores negativos, lo cual es un inconveniente para las transformaciones logarítmicas, se evalúa su significancia mediante una Prueba F-parcial.

La hipótesis es la siguiente:

$$H_0 : \beta_{INF} = 0 \text{ (no aporta al modelo)} \quad \text{vs} \quad H_1 : \beta_{INF} \text{ (si aporta al modelo)} \quad (22)$$

El estadístico de la prueba F_0 —parcial se calcula de la siguiente forma:

$$F_0 - \text{parcial} = \frac{SS_{Reg}(\beta_2 | \beta_1)/r}{MS_{Res}} \quad (23)$$

En este caso SS_{Reg} es la suma de cuadrado de la regresión, $r = 1$ el número de restricciones, MS_{Res} es el cuadro medio del error.

El resultado es el siguiente:

```
> F0_parcial
[1] 0.2064008
```

Con un p-value de:

```
> pf(F0_parcial,r,n-p,lower.tail = FALSE)
[1] 0.6511646
```

Dado que $p > 0.05$ no se rechaza H_0 , por lo cuál la variable no es significativa y se puede eliminar del modelo. Se propone una transformación logarítmica:

$$\ln(TUR) = \beta_0 + \beta_1 \ln(IPC) + \beta_2 \ln(PH) + \beta_3 \ln(GH) + \beta_4 \ln(PC) + \beta_5 \ln(PROD) + \beta_6 \ln(CL) + \epsilon \quad (24)$$

Aplicaremos selección de variables mediante AIC y BIC.

1. Selección de variables mediante AIC:

Se obtuvo lo siguiente al aplicar AIC:

```
Call:
lm(formula = log(TUR) ~ log(IPC) + log(GH) + log(PC) + log(PROD) +
    log(CL), data = Turismo)

Coefficients:
(Intercept)      log(IPC)      log(GH)      log(PC)      log(PROD)      log(CL)
      5.7765         0.3922         0.3175        -1.0035        -0.1103         0.1431
```

Esto nos indica que el modelo se plantea de la siguiente manera:

$$\ln(TUR) = \beta_0 + \beta_1 \ln(IPC) + \beta_2 \ln(GH) + \beta_3 \ln(PC) + \beta_4 \ln(PROD) + \beta_5 \ln(CL) \quad (25)$$

Al aplicar el summary al modelo AIC se obtuvieron lo siguiente:

```
> summary(regresion_step_loglog)
```

Call:

```
lm(formula = log(TUR) ~ log(IPC) + log(GH) + log(PC) + log(PROD) +  
    log(CL), data = Turismo)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.073592	-0.012090	0.001253	0.012713	0.051344

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	5.77646	0.59864	9.649	3.61e-14	***
log(IPC)	0.39217	0.01551	25.283	< 2e-16	***
log(GH)	0.31753	0.04916	6.459	1.55e-08	***
log(PC)	-1.00353	0.14487	-6.927	2.33e-09	***
log(PROD)	-0.11034	0.05765	-1.914	0.06003	.
log(CL)	0.14312	0.04040	3.542	0.00074	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02306 on 65 degrees of freedom

Multiple R-squared: 0.9322, Adjusted R-squared: 0.927

F-statistic: 178.8 on 5 and 65 DF, p-value: < 2.2e-16

Multicolinealidad: Por medio del $VIF_j = \frac{1}{1-R_j^2}$, se obtuvo lo siguiente:

```
>vif(regresion_step_loglog)  
log(IPC) log(GH) log(PC) log(PROD) log(CL)  
1.560288 12.611544 3.059253 9.237734 2.217193
```

Como algunos de los valores $VIF > 5$ implica que hay multicolinealidad.

2. Selección de variables mediante BIC:

Al aplicar la especificación del modelo BIC se obtuvo lo siguiente:

```
> which.min(resultado_regsubsets$bic)  
[1] 4  
> resultado_regsubsets$which[4,]  
(Intercept) log(IPC) log(PH) log(GH) log(PC) log(PROD) log(CL)  
TRUE TRUE FALSE TRUE TRUE FALSE TRUE
```

Esto nos quiere decir que el modelo puede plantear de la siguiente forma:

$$\ln(TUR) = \beta_0 + \beta_1 \ln(IPC) + \beta_2 \ln(GH) + \beta_3 \ln(PC) + \beta_4 \ln(CL) \quad (26)$$

Al aplicar el summary al modelo BIC obtuvimos lo siguiente:

```
> summary(modelo_BIC)
```

Call:

```
lm(formula = log(TUR) ~ log(IPC) + log(GH) + log(PC) + log(CL),
    data = Turismo)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.071157	-0.014410	-0.000354	0.014976	0.054092

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.90271	0.39498	12.413	< 2e-16 ***
log(IPC)	0.37686	0.01356	27.801	< 2e-16 ***
log(GH)	0.23242	0.02138	10.871	2.38e-16 ***
log(PC)	-0.80979	0.10570	-7.661	1.07e-10 ***
log(CL)	0.12918	0.04053	3.187	0.0022 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02352 on 66 degrees of freedom

Multiple R-squared: 0.9284, Adjusted R-squared: 0.9241

F-statistic: 213.9 on 4 and 66 DF, p-value: < 2.2e-16

Multicolinealidad: Por medio del $VIF_j = \frac{1}{1-R_j^2}$, se obtuvo lo siguiente:

```
> vif(modelo_BIC)
log(IPC) log(GH) log(PC) log(CL)
1.145395 2.292969 1.565528 2.145067
```

Como todos los valores $VIF < 5$ implica que no hay multicolinealidad.

El modelo AIC no cumple con el supuesto de multicolinealidad a diferencia del BIC, que si cumple con dicho supuesto.

Dado que la validez de la inferencia estadística depende del cumplimiento de los supuestos del modelo de regresión, se selecciona el modelo BIC como el modelo final.

3.2. Interpretación de los modelos

El modelo quedó de la siguiente manera:

$$\ln(TUR) = 4.90271 + 0.37686 \ln(IPC) + 0.23242 \ln(GH) - 0.80979 \ln(PC) + 0.12918 \ln(CL) \quad (27)$$

El ANOVA del modelo BIC se obtuvo lo siguiente:

```
> anova(modelo_BIC)
Analysis of Variance Table

Response: log(TUR)
      Df Sum Sq Mean Sq F value    Pr(>F)
log(IPC)   1 0.37740  0.37740  681.948 < 2.2e-16 ***
log(GH)    1 0.06335  0.06335  114.472 4.669e-16 ***
log(PC)    1 0.02721  0.02721   49.170 1.541e-09 ***
log(CL)    1 0.00562  0.00562   10.156 0.002198 **
Residuals 66 0.03653  0.00055
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Por lo cual se concluye que IPC: altamente significativa, GH: altamente significativa y PC: altamente significativa. El ANOVA confirma que todas las variables incluidas aportan significativamente al modelo.

Interpretación de los coeficientes de regresión:

El intercepto ($\beta_0 = 4.9027$), representa el valor esperado de $\ln(TUR)$ cuando todas las variables explicativas toman valor 1.

IPC ($\beta_1 = 0.3769$), un aumento del 1 % en *IPC* aumenta el turismo en aproximadamente 0.35689 %. Un aumento en el nivel general de precios está asociado con un incremento en la actividad turística, posiblemente reflejando mayor dinamismo económico.

GH ($\beta_2 = 0.2324$), si *GH* aumenta 1 % incrementa el turismo en 0.2324 %. El crecimiento en el gasto hotelero o actividad del sector impulsa el turismo.

PC ($\beta_3 = -0.8098$), si *PC* aumenta 1 % el turismo disminuye aproximadamente 0.8305 %. A mayores personas en el comercio minorista, se reduce la demanda turística.

CL ($\beta_4 = 0.1292$), si *CL* aumenta 1 % el turismo aumenta en aproximadamente 0.1292 %. Con mejores condiciones económicas o de crédito favorecen el turismo.

Interpretación de las pruebas de significancia:

Se evalúa:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0 \quad (28)$$

Variable	t value	p-value	Decisión
Intercepto	12.413	$< 2e - 16$	Rechazar H_0 es significativo
$\log(IPC)$	27.801	$< 2e - 16$	Rechazar H_0 es significativo
$\log(GH)$	10.871	$2.38e - 16$	Rechazar H_0 es significativo
$\log(PC)$	-7.661	$1.07e - 10$	Rechazar H_0 es significativo
$\log(CL)$	3.187	0.0022	Rechazar H_0 es significativo

Cuadro 4: Resultados de pruebas de significancia de los parámetros en el modelo Log-log

Todos los coeficientes tienen p-values extremadamente pequeños ($p < 0.05$). Por lo cual, se rechaza H_0 para todas las variables. Todas las variables incluidas en el modelo son estadística-mente significativas y contribuyen de manera individual a explicar el turismo.

Interpretación de la significancia global del modelo (Prueba F):

Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0 \quad \text{vs} \quad H_1 : \text{al menos uno es diferente de } 0 \quad (29)$$

Se obtuvo el siguiente resultado: $F = 213.9$ y $p < 2.2 \times 10^{-16}$.

Se rechaza H_0 , por lo que el modelo es globalmente significativo. Es decir, el conjunto de variables explica de manera conjunta el comportamiento del turismo.

Interpretación del ANOVA:

Variable	F value	p-value
$\log(IPC)$	681.948	$< 2.2e - 16$
$\log(GH)$	114.472	$4.669e - 16$
$\log(PC)$	49.170	$1.541 - 09$
$\log(CL)$	10.156	0.002198

Cuadro 5: Interpretación del ANOVA

$\log(IPC)$ es la variable más significativa indicando una fuerte relación con el turismo.

Por otra parte, el $\log(GH)$ y $\log(PC)$, también presentan alta significancia estadística.

Finalmente, $\log(CL)$ aunque con menor magnitud relativa, sigue siendo significativa al 5 % .

Los residuos mostraron una variabilidad no explicada de 0.03653 y un error medio de 0.00055, esto indica que el modelo logra explicar gran parte de la variabilidad total.

Así mismo, tenemos un $R^2 = 0.9284$ y una $R^2_{ajustada} = 0.9241$. Esto nos indica, que el modelo explica aproximadamente el 92.84 % de la variabilidad del turismo, lo cual indica un excelente ajuste.

Intervalos de respuesta media y predicción:

Para el intervalo de respuesta media, tenemos el valor estimado $\log(\hat{TUR}) = 4.4758$ y el intervalo al 95 %=

[4.4657, 4.4859].

Para interpretar económicamente, es más útil podemos regresar lo a la escala original. $TUR = e^{\log(TUR)} \cdot e^{4.4758} = 88.1$. Este intervalo indica que el promedio esperado del logaritmo del turismo se encuentra entre 4.4657 y 4.4859, con un 95 % de confianza. O si lo convertimos se encuentra entre $[e^{4.4657}, e^{4.4859}] = [87.2, 88.8]$

Intervalo de predicción, tenemos el valor estimado, $\log(\hat{TUR}) = 4.4758$ y el intervalo [4.4277, 4.5238], o si lo convertimos a escala original $[e^{4.4277}, e^{4.5238}] = [83.9, 92.2]$. Este intervalo indica que una observación futura del logaritmo del turismo puede tomar valores dentro de ese rango con un 95 % de confianza.

3.3. Validación de los modelos

Identificación de valores atípicos: Se utilizan residuos estudentizados,

$$t_i > t_{\alpha/2, n-k-1} \quad (30)$$

En este caso $t_{crit} = 1.9977$, como resultado se identificaron como valores atípicos las observaciones.

```
> atipicos2
2 5 6 9
```

Estas observaciones presentan residuales significativamente grandes, lo que indica que; el modelo no las explica adecuadamente y pueden distorsionar la estimación de parámetros.

Detección de puntos de apalancamiento: Se analizaron los valores de leverage y se utilizó el siguiente criterio:

$$h_i > \frac{3(k+1)}{n} \quad (31)$$

Como resultado se detecto como punto de apalancamiento:

50

Distancia de Cook: En este caso no hay ningún valor tal que $D_i > 1$, por lo que no hay puntos influyentes por Cook.

Eliminación de observaciones: Se decidieron eliminar 5 observaciones, 2, 5, 6, 9, 50. Los cuales representan el 7 % de la muestra. Se decidieron eliminar ya que genera una distorsión en la estimación y eliminarlos mejora los supuestos del modelo.

Por lo cuál después de eliminar valores atípicos el modelo quedó de la siguiente manera:

$$TUR = 4.69510 + 0.35922 \ln(IPC) + 0.22641 \ln(GH) - 0.70547 \ln(PC) + 0.09470 \ln(CL) \quad (32)$$

Verificación de supuestos:

1. Homocedasticidad (Breush-Pagan): Tenemos las siguientes hipótesis

$$H_0 : \text{varianza constante} \quad \text{vs} \quad H_1 : \text{Heterocedasticidad} \quad (33)$$

Se obtuvo el siguiente resultado:

```
> bptest(modelo_limpio_BIC)
studentized Breusch-Pagan test

data:  modelo_limpio_BIC
BP = 3.5918, df = 4, p-value = 0.4641
```

Como el $p > 0.05$ no se rechaza H_0 . Por lo cual, concluimos que se cumple homocedasticidad.

2. Independencia (Box-Pierce):

En donde tenemos las siguientes hipótesis

$$H_0 : \text{No autocorrelación} \quad \text{vs} \quad H_1 : \text{Autocorrelación} \quad (34)$$

En este caso se obtuvo el siguiente resultado:

```
> Box.test(residuales_regresion_limpia_BIC, lag=5, type="Box-Pierce")

Box-Pierce test

data:  residuales_regresion_limpia_BIC
X-squared = 38.485, df = 5, p-value = 3.015e-07
```

Como el $p < 0.05$, nos dice que se rechaza H_0 y que si existe auto correlación en los residuos. Por lo cual, no se cumple el supuesto.

3. Media cero:

Se quiere probar que

$$H_0 : E(\epsilon) = 0 \quad \text{vs} \quad H_1 : E(\epsilon) \neq 0 \quad (35)$$

```
> t.test(residuales_regresion_limpia_BIC, alternative= "two.sided", mu=0, paired= FALSE,
conf.level=0.95)
```

One Sample t-test

```
data:  residuales_regresion_limpia_BIC
```

```
t = 2.0528e-16, df = 65, p-value = 1
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.004467105  0.004467105
sample estimates:
mean of x
4.591689e-19
```

Como el $p > 0.05$, se cumple el supuesto de media cero.

4. Normalidad (Shapiro-Wilk): Se requiere comparar

$$H_0 : \text{Normalidad} \quad \text{vs} \quad H_1 : \text{No normalidad} \quad (36)$$

Shapiro-Wilk normality test

```
data:  residuales_regresion_limpia_BIC
W = 0.97313, p-value = 0.1618
```

Como el $p > 0.05$, implica que no se rechaza normalidad.

A continuación se presenta el ANOVA y summary del modelo ganador después del procedimiento de los valores atípicos y apalacamientos.

```
> anova(modelo_limpio_BIC)
Analysis of Variance Table
```

Response: log(TUR)

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
log(IPC)	1	0.310663	0.310663	882.9294	< 2.2e-16 ***
log(GH)	1	0.024382	0.024382	69.2951	1.219e-11 ***
log(PC)	1	0.017665	0.017665	50.2057	1.651e-09 ***
log(CL)	1	0.002842	0.002842	8.0772	0.006088 **
Residuals	61	0.021463	0.000352		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> summary(modelo_limpio_BIC)
```

Call:

```
lm(formula = log(TUR) ~ log(IPC) + log(GH) + log(PC) + log(CL),
    data = Turismo_limpio_BIC)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.044281	-0.013128	-0.001196	0.012244	0.030627

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.69510	0.34025	13.799	< 2e-16 ***
log(IPC)	0.35922	0.01207	29.770	< 2e-16 ***
log(GH)	0.22641	0.02169	10.439	3.36e-15 ***
log(PC)	-0.70547	0.09287	-7.596	2.18e-10 ***
log(CL)	0.09470	0.03332	2.842	0.00609 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01876 on 61 degrees of freedom

Multiple R-squared: 0.9431, Adjusted R-squared: 0.9393

F-statistic: 252.6 on 4 and 61 DF, p-value: < 2.2e-16

Se redujo muy poco el error estándar, con una diferencia absoluta de 0.0147. Y aumento un poco la R^2 ajustada. Igualmente podemos observar todas las variables son significativas y hay un mejor cumplimiento de supuestos.

Interpretación de las pruebas de significancia:

Se evalúa:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0 \quad (37)$$

Variable	t value	p-value	Conclusión
Intersecto	13.799	$< 2e - 16$	Significativo
$\log(IPC)$	29.770	$< 2e - 16$	Significativo
$\log(GH)$	10.439	$3.36e - 15$	Significativo
$\log(PC)$	-7.596	$2.18e - 10$	Significativo
$\log(CL)$	2.842	0.00609	Significativo

Cuadro 6: Resultados de pruebas de significancia de los parámetros

Todos los coeficientes tienen p-values extremadamente pequeños ($p < 0.05$). Por lo cual, se rechaza H_0 para todas las variables. Todas las variables incluidas en el modelo son estadísticamente significativas y contribuyen de manera individual a explicar el turismo.

Interpretación de la significancia global del modelo (Prueba F):

Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \quad \text{vs} \quad H_1 : \text{al menos uno es diferente de } 0 \quad (38)$$

Se obtuvo el siguiente resultado: $F = 252.6$ y $p < 2.2 \times 10^{-16}$.

El modelo es globalmente significativo, es decir, el conjunto de variables $\log(IPC)$, $\log(GH)$, $\log(CL)$ y $\log(PC)$ explican de manera significativa la variabilidad de TUR . Las variables incluidas capturan de forma adecuada los factores relevantes que afectan la dinámica del turismo.

Interpretación del ANOVA:

Variable	F value	p-value	Interpretación
$\log(IPC)$	882.9294	$< 2.2e - 16$	Mayor Contribución
$\log(GH)$	69.2951	$1.219e - 11$	Contribución importante
$\log(PC)$	50.2057	$1.651e - 09$	Contribución significativa
$\log(CL)$	8.0772	0.006088	Contribución significativa

Cuadro 7: Interpretación del ANOVA

$\log(IPC)$ es la variable más importante del modelo, ya que tiene el mayor $F = 882.93$, por lo que explica la mayor parte de la variabilidad del turismo.

Por otra parte, el $\log(GH)$ y $\log(PC)$, tiene una contribución relevantes y explican una parte importante de la variabilidad.

Finalmente, $\log(CL)$, tiene el menor F , pero sigue siendo significativa, aporta información adicional al modelo.

Así mismo, tenemos un $R^2 = 0.9431$ y una $R^2_{ajustada} = 0.9393$. Esto nos indica, que el modelo explica aproximadamente el 94.31 % de la variabilidad del turismo, lo cual indica un excelente ajuste.

Intervalos de respuesta media y predicción:

Para el intervalo de respuesta media, tenemos el valor estimado $\log(\hat{TUR}) = 4.4793$ y el intervalo al 95 % es el siguiente $[4.4706, 4.4880]$.

Para interpretar económicamente, es más útil podemos regresar lo a la escala original. $TUR = e^{\log(TUR)} \cdot e^{4.4758} = 88.1$. Este intervalo indica que el promedio esperado del logaritmo del turismo se encuentra entre 4.4706 y 4.4880, con un 95 % de confianza. O si lo convertimos se encuentra entre $[e^{4.4706}, e^{4.4880}] = [87.6, 89.0]$. Se observa que el intervalo es más estrecho que en el modelo con atípicos, lo que sugiere una mayor precisión en la estimación tras la depuración de los datos.

Intervalo de predicción, tenemos el valor estimado, $\log(\hat{TUR}) = 4.4793$ y el intervalo $[4.4408, 4.5178]$, o si lo convertimos a escala original $[e^{4.4408}, e^{4.5178}] = [84.7, 91.7]$. Este intervalo indica que una observación futura del logaritmo del turismo puede tomar valores dentro de ese rango con un 95 % de confianza. También se observa una ligera reducción en la amplitud del intervalo, lo que indica menor incertidumbre en las predicciones.

3.4. Propuesta y justificación de los mejores modelos

El modelo log-log permite interpretar directamente los coeficientes como elasticidades lo cual es muy útil en economía, ya que mide cambios porcentuales. Comparando con el modelo sin transformación, se reducen problemas de heterocedasticidad, se mejora la normalidad de los residuos, se obtiene un mejor ajuste. Por lo tanto, si tiene sentido utilizar la transformación log-log.

Interpretación de los coeficientes (modelo log-log):

Intercepto (4.69510): No tiene interpretación económica directa fuerte, porque implica cuando todas las variables valen 1.

Log(IPC) ($\beta_1 = 0.35922$): Si el *IPC* aumenta en 1 %, *TUR* aumenta en aproximadamente 0.36 %, mantenimiento constantes las demás variables. El turismo responde positivamente al nivel de precios.

Log(GH) ($\beta_2 = 0.22641$): Si el *GH* aumenta en 1 %, *TUR* aumenta 0.23 %, mantenimiento constantes las demás variables. *GH* impulsa el turismo, pero con menor elasticidad que *IPC*.

Log(PC) ($\beta_3 = -0.70547$): Si el *PC* aumenta en 1 %, *TUR* disminuye en 0.71 %. Es una relación inversa fuerte, *PC* probablemente representa personas ocupadas en el sector minorista.

Log(CL) ($\beta_4 = 0.09470$): Si el *CL* aumenta en 1 %, *TUR* aumenta en 0.095 %. El efecto es positivo pero pequeño. Es una variable con impacto menor en comparación con las demás.

4. Modelo Log-Lin

4.1. Selección de los mejores modelos

Análogamente a los modelos anteriores, se hizo uso de dos criterios de selección: AIC y BIC, las cuales ya fueron explicadas con anterioridad.

1. AIC (comando step). Del summary del modelo AIC se obtuvo lo siguiente:

Call:

```
lm(formula = log(TUR) ~ IPC + PH + GH + PC + INF, data = Turismo)
```

Y que el modelo se puede plantear de la siguiente manera:

$$\ln(TUR) = \beta_0 + \beta_1 IPC + \beta_2 PH + \beta_3 GH + \beta_4 PC + \beta_5 INF + \epsilon \quad (39)$$

Al aplicar el comando summary al modelo obtenido, se obtuvo lo siguiente:

Call:

```
lm(formula = log(TUR) ~ IPC + PH + GH + PC + INF, data = Turismo)
```

Residuals:

Min	1Q	Median	3Q	Max
-----	----	--------	----	-----

```
-0.077532 -0.011614 0.001044 0.016840 0.047113
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.8648408  0.0977021  49.793  < 2e-16 ***
IPC          0.0034930  0.0002136  16.353  < 2e-16 ***
PH          -0.0020773  0.0009496  -2.187   0.0323 *
GH           0.0036026  0.0004394   8.200 1.29e-11 ***
PC          -0.0078804  0.0013658  -5.770 2.40e-07 ***
INF          -0.0085691  0.0115402  -0.743   0.4604
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02641 on 65 degrees of freedom

Multiple R-squared: 0.9112, Adjusted R-squared: 0.9043

F-statistic: 133.3 on 5 and 65 DF, p-value: < 2.2e-16

donde el modelo no es globalmente significativo, ya que no hay evidencia suficiente para decir que la variable INF afecte a TUR en este modelo.

Y el supuesto de multicolinealidad se ve de esta manera:

```
      vif(regresion_step_loglin)
      IPC      PH      GH      PC      INF
2.209535 5.553756 3.457649 2.109891 1.117341
```

2. BIC (comando regsubsets). Del summary del modelo BIC se obtuvo lo siguiente:

```
Call:
lm(formula = log(TUR) ~ IPC + PH + GH + PC, data = Turismo)
```

Lo que nos dice que se puede plantear de esta manera:

$$\ln(TUR) = \beta_0 + \beta_1 IPC + \beta_2 PH + \beta_3 GH + \beta_4 PC + \epsilon \quad (40)$$

Al aplicar el comando summary al modelo obtenido, se obtuvo lo siguiente:

```
Call:
lm(formula = log(TUR) ~ IPC + PH + GH + PC, data = Turismo)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.078515	-0.013164	0.001719	0.017863	0.048663

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.8652208	0.0973682	49.967	< 2e-16 ***
IPC	0.0035093	0.0002117	16.574	< 2e-16 ***
PH	-0.0018985	0.0009155	-2.074	0.042 *
GH	0.0035012	0.0004162	8.413	4.83e-12 ***
PC	-0.0080068	0.0013505	-5.929	1.23e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02632 on 66 degrees of freedom

Multiple R-squared: 0.9104, Adjusted R-squared: 0.905

F-statistic: 167.7 on 4 and 66 DF, p-value: < 2.2e-16

Donde el modelo es globalmente significativo a un nivel de confianza del 90 %.

Con un supuesto de multicolinealidad que arroja estos valores:

	vif(modelo_BIC)			
	IPC	PH	GH	PC
	2.186123	5.196941	3.123520	2.077153

Al compararse los supuestos de multicolinealidad, en ambos modelos, todos los valores se mantienen debajo del valor 10, lo que garantiza estimadores más estables. Al eliminarse la variable INF se reduce de manera leve la colinealidad. Se selecciona BIC como el modelo final.

4.2. Interpretación de los modelos

El modelo queda de la siguiente manera:

$$\ln(TUR) = 4.8652208 + 0.0035093IPC - 0.0018985PH + 0.0035012GH - 0.0080068PC \quad (41)$$

El ANOVA del modelo ganador obtuvo lo siguiente:

Analysis of Variance Table

Response: log(TUR)

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
IPC	1	0.36243	0.36243	523.3602	< 2.2e-16 ***
PH	1	0.00363	0.00363	5.2382	0.02531 *

```

GH          1 0.07400 0.07400 106.8610 1.959e-15 ***
PC          1 0.02434 0.02434  35.1491 1.230e-07 ***
Residuals 66 0.04571 0.00069
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Se concluye que *IPC*, *GH* y *PC* son altamente significativos, mientras que *PH* es significativa al 95 %. El ANOVA confirma que todas las variables aportan de manera significativa al modelo.

Interpretación de los coeficientes de regresión: El intercepto ($\beta_0 = 4.8652208$), representa el valor esperado de *TUR* cuando $IPC = PH = GH = PC = 0$. Aunque no tiene interpretación económica directa, sirve como punto base del modelo.

IPC ($\beta_1 = 0.0035093$), manteniendo constantes *GH*, *PH* y *PC*, un incremento de una unidad en *IPC* aumenta el turismo en aproximadamente 0.35282 %. El *IPC* tiene un efecto positivo significativo sobre el turismo, lo que sugiere que mayor dinamismo económico está asociado con mayor actividad turística.

PH ($\beta_2 = -0.0018985$), manteniendo constantes *IPC*, *GH* y *PC*, un aumento de una unidad en *PH* disminuye el turismo en 0.18985 %. Esta variable no es altamente significativa, pero si lo fuera, la interpretación correcta sería que cuando los precios del sector hotelero aumentan, la actividad turística tiende a bajar.

GH ($\beta_3 = 0.0035012$), manteniendo constantes *PH*, *PC* y *IPC*, un aumento de una unidad en *GH* aumenta el turismo en aproximadamente 0.35012 %. Es decir, entre más gasto haya hotelero haya, el turismo tiende a tener un incremento.

PC ($\beta_4 = -0.0080068$), manteniendo constantes *IPC*, *PH* y *GH*, un aumento en una unidad en *PC* reduce el turismo en aproximadamente 0.80068 % unidades. Valida que el aumento de personal ocupado en comercio minorista hace que la actividad turística descienda.

Interpretación de los intervalos de respuesta media y predicción:

Para el intervalo de respuesta media, está el valor estimado $\hat{y} = 4.545546$ y el intervalo, al 95 % de confianza = [4.52, 4.56]. Se estima que el valor promedio de índice de turismo, ante los valores independientes ingresados, se encuentran entre $e^{4.52}$ y $e^{4.56}$ con una estimación puntual de $e^{4.54}$.

Para el intervalo de predicción, el valor estimado $\hat{y} = 4.545546$ y el intervalo, al 95 % de confianza = [4.49, 4.60]. Si observa un trimestre específico con los valores asignados, el índice de turismo se encontrará entre $e^{4.49}$ y $e^{4.6}$ unidades.

4.3. Validación de los modelos

Análogamente a los modelos anteriores, para la identificación de valores atípicos se utilizaron residuos studentizados, en el que se comparo con el cuantil de una t-student.

Como resultado, se identificaron como valores atípicos las siguientes observaciones:

```

> atipicos2
2 5 9
2 5 9

```

Estas tres observaciones presentan residuales grandes significativamente, es decir, el modelo no logra explicarlas adecuadamente y distorsiona la estimación de parámetros.

Para la detección de puntos de apalancamiento, dio como resultado:

```
> influyentes1
50 51
50 51
```

En este caso, solo hay dos valores extremos en las variables regresoras.

Por medio de la distancia de Cook, no se observaron no hubo ningún valor.

Los valores que se decidieron eliminar fueron los que se encontraban en las filas 2, 5, 9, 50 y 51, como estos valores afectan la normalidad y la varianza, además los puntos de apalancamiento pueden sesgar la regresión. Por lo cual, después de eliminar valores atípicos e influyentes, el modelo quedó de la siguiente manera:

$$TUR = 4.843231 + 0.003528IPC - 0.001050PH + 0.003263GH - 0.008370PC \quad (42)$$

Verificación de supuestos:

1. Homocedasticidad (Breush-Pagan): Tenemos las siguientes hipótesis

$$H_0 : \text{varianza constante} \quad \text{vs} \quad H_1 : \text{Heterocedasticidad} \quad (43)$$

Se obtuvo el siguiente resultado:

```
> bptest(modelo_limpio_BIC)

studentized Breusch-Pagan test

data:  modelo_limpio_BIC
BP = 1.683, df = 4, p-value = 0.7938
```

Como el $p > 0.05$ no se rechaza H_0 . Por lo cual, concluimos que se cumple homocedasticidad.

2. Independencia (Box-Pierce):

En donde tenemos las siguientes hipótesis

$$H_0 : \text{No autocorrelación} \quad \text{vs} \quad H_1 : \text{Autocorrelación} \quad (44)$$

En este caso se obtuvo el siguiente resultado:

```
> Box.test(residuales_regresion_limpia_BIC, lag=5, type="Box-Pierce")

Box-Pierce test
```

```
data:  residuales_regresion_limpia_BIC
X-squared = 34.529, df = 5, p-value = 1.868e-06
```

Como el $p < 0.05$, nos dice que se rechaza H_0 y que si existe autocorrelación en los residuos. Por lo cual, no se cumple el supuesto.

3. Media cero: Se quiere probar que

$$H_0 : E(\epsilon) = 0 \quad \text{vs} \quad H_1 : E(\epsilon) \neq 0 \quad (45)$$

```
> t.test(residuales_regresion_limpia_BIC, alternative= "two.sided", mu=0, paired= FALSE,
conf.level=0.95)
```

One Sample t-test

```
data:  residuales_regresion_limpia_BIC
t = 3.2192e-16, df = 65, p-value = 1
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.005255559  0.005255559
sample estimates:
 mean of x
8.471356e-19
```

Como el $p > 0.05$, se cumple el supuesto de media cero.

4. Normalidad (Shapiro-Wilk): Se requiere comparar

$$H_0 : \text{Normalidad} \quad \text{vs} \quad H_1 : \text{No normalidad} \quad (46)$$

```
> shapiro.test(residuales_regresion_limpia_BIC)
```

Shapiro-Wilk normality test

```
data:  residuales_regresion_limpia_BIC
W = 0.9692, p-value = 0.09969
```

Como el $p > 0.05$, implica que no se rechaza normalidad.

A continuación se presenta el ANOVA y summary del modelo ganador después del procedimiento de los valores atípicos y apalacamientos.

```

> anova(modelo_limpio_BIC)
Analysis of Variance Table

Response: log(TUR)

      Df Sum Sq Mean Sq F value    Pr(>F)
IPC      1 0.32765  0.32765 672.7680 < 2.2e-16 ***
PH       1 0.00000  0.00000   0.0037   0.9519
GH       1 0.02586  0.02586  53.0952 7.446e-10 ***
PC       1 0.02464  0.02464  50.5940 1.482e-09 ***
Residuals 61 0.02971 0.00049
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary(modelo_limpio_BIC)

Call:
lm(formula = log(TUR) ~ IPC + PH + GH + PC, data = Turismo_limpio_BIC)

Residuals:
      Min       1Q   Median       3Q      Max
-0.048766 -0.013451  0.001082  0.015171  0.035341

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.8432305   0.0858559   56.411 < 2e-16 ***
IPC          0.0035282   0.0001864   18.928 < 2e-16 ***
PH         -0.0010497   0.0008522   -1.232   0.223
GH          0.0032630   0.0005137    6.352 2.97e-08 ***
PC         -0.0083701   0.0011767   -7.113 1.48e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02207 on 61 degrees of freedom
Multiple R-squared:  0.9272, Adjusted R-squared:  0.9224
F-statistic: 194.1 on 4 and 61 DF, p-value: < 2.2e-16

```

Interpretación de las pruebas de significancia:

Se evalúa:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0 \quad (47)$$

Variable	t value	p-value	Conclusión
Intersecto	56.411	$< 2e - 16$	Significativo
<i>IPC</i>	18.928	$< 2e - 16$	Significativo
<i>PH</i>	-1.232	0.223	No significativo
<i>GH</i>	6.352	$2.97e - 08$	Significativo
<i>PC</i>	-7.113	$1.48e - 09$	Significativo

Cuadro 8: Resultados de pruebas de significancia de los parámetros

A un nivel de significancia del 5 %, se observa que el Intercepto, IPC, GH y PC tienen p-values extremadamente pequeños. Por lo tanto, se rechaza la hipótesis nula H_0 para estas variables, concluyendo que son estadísticamente significativas. Sin embargo, para la variable PH, el p-value es de 0.223, lo cual es superior a 0.05. En este caso, no se rechaza H_0 , lo que indica que el personal ocupado en hotelería no contribuye de manera significativa a explicar el turismo en presencia de las demás variables del modelo.

Interpretación de la significancia global del modelo (Prueba F):

Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0 \quad \text{vs} \quad H_1 : \text{al menos uno es diferente de } 0 \quad (48)$$

Se obtuvo el siguiente resultado: $F = 194.1$ y $p < 2.2 \times 10^{-16}$.

El modelo es globalmente significativo, es decir, el conjunto de variables *IPC*, *PH*, *GH* y *PC* explica de manera significativa la variabilidad de *TUR*.

Interpretación del ANOVA:

Variable	F value	p-value	Interpretación
<i>IPC</i>	672.768	$< 2e - 16$	Mayor Contribución
<i>PH</i>	0.0037	0.9519	Contribución no importante
<i>GH</i>	53.0952	$7.44e - 10$	Contribución significativa
<i>PC</i>	50.5940	$1.482e - 09$	Contribución significativa

Cuadro 9: Interpretación del ANOVA

IPC: Con un valor F de 672.768 y un p-value prácticamente de cero, es la variable con mayor poder explicativo. Esto confirma que el nivel general de precios es la principal causa de los cambios en el flujo turístico.

PH: Al ser el p-value muy alto, no hay evidencia estadística suficiente de que los precios hoteleros aporten información relevante al modelo una vez que ya se toman en cuenta las otras variables. Su contribución es prácticamente nula en este conjunto de datos.

GH: Tiene un p-value muy por debajo de 0.05, y un F-valor de 53.0952, lo que indica que tiene una relevancia muy alta en el modelo y es necesaria para explicar cómo se comporta el turismo y que el gasto en hospedaje sí aumenta el turismo.

PC: Con un p-value debajo y un F-valor alto, nos indica que tiene una gran significancia en el modelo y confirma que la cantidad de personas en comercio minorista sí afecta la demanda turística.

Interpretación de los intervalos de respuesta media y predicción:

Para el intervalo de respuesta media, se obtiene el valor estimado de $\hat{y} = 4.550333$, con un intervalo, al 95 % de confianza de $[4.53, 4.56]$. Se estima que el valor promedio de índice de turismo, ante los valores ingresados, se encuentran entre $e^{4.53}$ y $e^{4.56}$ con una estimación puntual de $e^{4.55}$.

Para el intervalo de predicción, el valor estimado $\hat{y} = 4.550333$ y el intervalo, al 95 % de confianza de $[4.5, 4.59]$. Si se observa un trimestre específico (sin valores atípicos) con los valores propuestos, el índice de turismo se encontrará entre $e^{4.5}$ y $e^{4.59}$ unidades.

4.4. Propuesta y justificación de los mejores modelos

El uso de la transformación Log-Lin es fundamental porque deja interpretar la relación entre las variables en términos de tasas de crecimiento porcentual. Este modelo logra mostrar con precisión cómo un incremento en una unidad impacta de manera directa en la variación porcentual del turismo. De igual manera, se logra ver un modelo mucho más estable que cumple con supuestos.

Interpretación de los coeficientes de regresión: El intercepto ($\beta_0 = 4.8432305$), representa el valor esperado de TUR cuando $IPC=PH=GH=PC=0$. No tiene interpretación económica directa, solo sirve como base del modelo.

IPC ($\beta_1 = 0.0035282$), mientras se mantienen constantes PH, GH y PC, el incremento de una unidad en el IPC aumenta el turismo 0.35282 %. Es un valor positivo y altamente significativa, que confirma que el crecimiento económico aumenta el sector turístico.

PH ($\beta_2 = -0.0010497$), nos indica que el aumento en el PH reduce el turismo un 0.10497 %. Como esta variable es estadísticamente significativa, no existe evidencia suficiente para decir que el PH afecte al turismo.

GH ($\beta_3 = 0.0032630$), cuando se mantienen constantes los otros factores, cada unidad aumentada en GH, el turismo aumenta un 0.3263 %. Es altamente significativa, lo que confirma la idea de que, cuando hay más gasto en el sector hotelero, hay más actividad turística.

PC ($\beta_4 = -0.0083701$), manteniendo las demás regresoras constantes, cada unidad que aumente el PC, decrementa el turismo un 0.83701 %. La significancia alta nos confirma que el turismo es sensible a la cantidad de personal ocupado en comercio minorista.

5. Modelo estandarizado

5.1. Selección de los mejores modelos

Para poder identificar, nuevamente se usaron dos metodologías para la selección de variables: stepwise y regsubsets.

1. AIC (comando step): Cuando se aplica la especificación del modelo se obtiene lo siguiente:

Call:

```
lm(formula = TUR ~ 0 + IPC + PH + GH + PC + CL, data = Turismo_std)
```

Esto nos indica que se puede plantear de la siguiente forma:

$$TUR = \beta_1 IPC + \beta_2 PH + \beta_3 GH + \beta_4 PC + \beta_5 CL + \epsilon \quad (49)$$

Cuando se aplica el summary al modelo AIC se obtiene el siguiente resultado:

```
Call:
lm(formula = TUR ~ 0 + IPC + PH + GH + PC + CL, data = Turismo_std)

Residuals:
    Min       1Q   Median       3Q      Max
-0.80224 -0.15872 -0.00577  0.17991  0.47097

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
IPC   0.92935     0.05049  18.408 < 2e-16 ***
PH  -0.15911     0.07730  -2.058  0.0435 *
GH   0.61588     0.07322   8.411 4.87e-12 ***
PC  -0.34489     0.05514  -6.255 3.34e-08 ***
CL   0.10382     0.05072   2.047  0.0446 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2835 on 66 degrees of freedom
Multiple R-squared:  0.9242, Adjusted R-squared:  0.9185
F-statistic: 161 on 5 and 66 DF, p-value: < 2.2e-16
```

El modelo sí es globalmente significativo a un nivel de confianza del 95 %, es decir, todas las variables aportan de manera significativa al modelo.

El supuesto de multicolinealidad arroja estos resultados:

```
> vif(regresion_step_std)
IPC      PH      GH      PC      CL
2.220394 5.205880 4.670420 2.648294 2.240820
```

2. BIC (comando regsubsets). Cuando se aplicó la especificación del modelo se obtuvo lo que sigue:

```
Call:
lm(formula = TUR ~ 0 + IPC + GH + PC, data = Turismo_std)
```

El cual se puede plantear de la siguiente manera:

$$TUR = \beta_1 IPC + \beta_2 GH + \beta_3 PC + \epsilon \quad (50)$$

Cuando se aplica el summary al modelo obtenido, nos da los siguientes valores:

```
Call:
lm(formula = TUR ~ 0 + IPC + GH + PC, data = Turismo_std)

Residuals:
    Min       1Q   Median       3Q      Max
-0.90920 -0.16898  0.03196  0.19134  0.47696

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
IPC    0.98482    0.03783  26.036 < 2e-16 ***
GH     0.43701    0.03888  11.240 < 2e-16 ***
PC    -0.35024    0.04082  -8.581 1.93e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2959 on 68 degrees of freedom
Multiple R-squared:  0.915, Adjusted R-squared:  0.9112
F-statistic: 243.8 on 3 and 68 DF,  p-value: < 2.2e-16
```

El modelo propuesto por la selección de variables es globalmente significativo.

El supuesto de multicolinealidad arroja los siguientes resultados:

```
> vif(modelo_BIC)
IPC      GH      PC
1.143941 1.208607 1.331973
```

Cuando se comparan en ambos el resultado del supuesto de multicolinealidad, todos los valores se mantienen debajo de 10, particularmente con el comando regsubsets, se mantienen por debajo de 5. Se selecciona BIC como el modelo final.

5.2. Interpretación de los modelos

El ANOVA del modelo seleccionado dio los siguientes resultados:

```
anova(modelo_BIC)
Analysis of Variance Table
```

Response: TUR

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
IPC	1	51.349	51.349	586.507	< 2.2e-16 ***
GH	1	6.250	6.250	71.392	3.349e-12 ***
PC	1	6.447	6.447	73.632	1.934e-12 ***
Residuals	68	5.953	0.088		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Se concluye que las tres variables son altamente significativas, lo que aportan y explican de manera significativa al modelo.

Interpretación de los coeficientes de regresión: IPC ($\beta_1 = 0.98482$): Manteniendo constantes el GH y el PC, un incremento de una desviación estándar en el IPC se traduce en un aumento de aproximadamente 0.98482 desviaciones estándar en el turismo.

GH ($\beta_2 = 0.43701$): Manteniendo constantes el IPC y el PC, un aumento de una desviación estándar en GH incrementa el turismo en 0.43701 desviaciones estándar. Cuando la capacidad de consumo de los hogares mejora, estos destinan mayores recursos a actividades de recreación y viajes.

PC ($\beta_3 = -0.35024$): Manteniendo constantes el IPC y el GH, un aumento de una desviación estándar en PC reduce el turismo en aproximadamente 0.35024 desviaciones estándar. **Interpretación de las pruebas de significancia:**

Se evalúa:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0 \quad (51)$$

Variable	t value	p-value	Conclusión
<i>IPC</i>	26.036	$< 2e - 16$	Significativo
<i>GH</i>	11.240	$< 2e - 16$	Significativo
<i>PC</i>	-8.581	$1.93e - 12$	Significativo

Cuadro 10: Resultados de pruebas de significancia de los parámetros

Todas las variables son estadísticamente significativas, con $p < 0.05$. Por lo tanto, se rechaza H_0 .

Interpretación de la significancia global del modelo (Prueba F):

Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \quad \text{vs} \quad H_1 : \text{al menos uno es diferente de } 0 \quad (52)$$

Se obtuvo el siguiente resultado: $F = 243.8$ y $p < 2.2 \times 10^{-16}$.

El modelo es globalmente significativo y como $p < 0.05$ se rechaza H_0 . El coeficiente de determinación $R^2 = 0.915$ eso nos dice que el 91.5% de la variabilidad de *TUR* es explicada por *IPC*, *GH* Y *PC*. El $R^2_{ajustado} = 0.9112$, lo cual indica un buen ajuste incluso penalizando por número las variables. El error estándar residual $\sigma = 0.2959$, nos dice que en promedio, el modelo se equivoca ± 0.2959 unidades en *TUR*.

Intervalos de respuesta media y predicción:

Para el intervalo de respuesta media, se tiene el valor estimado de $\hat{y} = 1.53081$, con un intervalo al 95 % de confianza de $[1.27, 1.78]$. Si se repitieran demasiados trimestres bajo esas condiciones económicas, el promedio del índice de turismo estará entre 1.27 y 1.78 desviaciones estándar por encima de la media.

Para el intervalo de predicción, el valor estimado $\hat{y} = 1.530581$ y el intervalo, con un 95 % de confianza de $[0.9, 2.15]$. Si se quisiera predecir el flujo que turistas en un trimestre bajo condiciones parecidas, el valor individual del índice de turismo estará entre 0.9 y 2.15 desviaciones estándar respecto a la media.

5.3. Validación de los modelos

Identificación de valores atípicos: Como en los modelos anteriores, para poder identificar valores atípicos se hace una prueba t-student. Se identificaron como atípicos los siguientes:

```
> atipicos2
5  9 59
```

Estas tres observaciones tienen residuales significativamente grandes, lo que dice que, el modelo no puede explicarlas adecuadamente y puede que distorsiones la estimación de parámetros.

Detección de puntos de apalancamiento: Con el criterio anteriormente usado, se detectaron.

```
> influyentes1
50 51
```

Eliminación de observaciones: Al final se decidieron eliminar 5 observaciones, se deciden eliminar ya que provoca distorsión en la estimación y eliminarlos mejora significativamente los supuestos del modelo. El modelo queda de la siguiente manera después de eliminar valores atípicos:

$$TUR = 0.9578IPC + 0.4740GH - 0.3377PC \quad (53)$$

Verificación de supuestos:

1. Homocedasticidad (Breush-Pagan): Tenemos las siguientes hipótesis

$$H_0 : \text{varianza constante} \quad \text{vs} \quad H_1 : \text{Heterocedasticidad} \quad (54)$$

Se obtuvo el siguiente resultado:

```
> bptest(modelo_limpio_BIC)

studentized Breusch-Pagan test

data:  modelo_limpio_BIC
BP = 1.2185, df = 2, p-value = 0.5438
```

Como el $p > 0.05$ no se rechaza H_0 . Por lo cual, concluimos que se cumple homocedasticidad.

2. Independencia (Box-Pierce):

En donde tenemos las siguientes hipótesis

$$H_0 : \text{No autocorrelación} \quad \text{vs} \quad H_1 : \text{Autocorrelación} \quad (55)$$

En este caso se obtuvo el siguiente resultado:

```
Box.test(residuales_regresion_limpia_BIC, lag=5, type="Box-Pierce")
```

```
Box-Pierce test
```

```
data:  residuales_regresion_limpia_BIC
```

```
X-squared = 22.936, df = 5, p-value = 0.0003472
```

Como el $p < 0.05$, nos dice que se rechaza H_0 y que si existe auto correlación en los residuos. Por lo cual, no se cumple el supuesto.

3. Media cero:

Se quiere probar que

$$H_0 : E(\epsilon) = 0 \quad \text{vs} \quad H_1 : E(\epsilon) \neq 0 \quad (56)$$

```
t.test(residuales_regresion_limpia_BIC, alternative= "two.sided", mu=0, paired= FALSE, conf.level=0.95)
```

```
One Sample t-test
```

```
data:  residuales_regresion_limpia_BIC
```

```
t = 1.1582, df = 65, p-value = 0.251
```

```
alternative hypothesis: true mean is not equal to 0
```

```
95 percent confidence interval:
```

```
-0.02455594  0.09235392
```

```
sample estimates:
```

```
mean of x
```

```
0.03389899
```

Como el $p > 0.05$, se cumple el supuesto de media cero.

4. Normalidad (Shapiro-Wilk): Se requiere comparar

$$H_0 : \text{Normalidad} \quad \text{vs} \quad H_1 : \text{No normalidad} \quad (57)$$

```
> shapiro.test(residuales_regresion_limpia_BIC)
```

Shapiro-Wilk normality test

```
data:  residuales_regresion_limpia_BIC
W = 0.97282, p-value = 0.1557
```

Como el $p > 0.05$, implica que no se rechaza normalidad.

A continuación, se presenta el ANOVA y summary del modelo escogido después del procedimiento de valores atípicos y apalancamientos.

```
> anova(modelo_limpio_BIC)
Analysis of Variance Table
```

Response: TUR

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
IPC	1	47.183	47.183	792.448	< 2.2e-16 ***
GH	1	1.849	1.849	31.062	5.561e-07 ***
PC	1	5.027	5.027	84.432	3.057e-13 ***
Residuals	63	3.751	0.060		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> summary(modelo_limpio_BIC)
```

Call:

```
lm(formula = TUR ~ 0 + IPC + GH + PC, data = Turismo_limpio_BIC)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.46041	-0.14993	0.05335	0.20166	0.44308

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
IPC	0.95776	0.03276	29.235	< 2e-16 ***
GH	0.47397	0.05026	9.430	1.18e-13 ***
PC	-0.33766	0.03675	-9.189	3.06e-13 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.244 on 63 degrees of freedom

Multiple R-squared: 0.9351, Adjusted R-squared: 0.932

F-statistic: 302.6 on 3 and 63 DF, p-value: < 2.2e-16

Interpretación de las pruebas de significancia:

Se evalúa:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0 \quad (58)$$

Variable	t value	p-value	Conclusión
<i>IPC</i>	29.235	$< 2e - 16$	Significativo
<i>GH</i>	9.430	$1.18e - 13$	Significativo
<i>PC</i>	-9.189	$3.06e - 13$	Significativo

Cuadro 11: Resultados de pruebas de significancia de los parámetros

A un nivel de significancia 0.1%, es visible que *IPC*, *GH* y *PC*, tienen p-values extremadamente pequeños. Por lo tanto, se rechaza la hipótesis nula H_0 para estas variables, por lo que son estadísticamente significativas. Por lo que los Índices de precios al consumidor, Gasto Hotelero y Precios al Consumidor explican el turismo de manera significativamente al modelo.

Interpretación de la significancia global del modelo (Prueba F):

Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \quad \text{vs} \quad H_1 : \text{al menos uno es diferente de } 0 \quad (59)$$

Se obtuvo el siguiente resultado: $F = 302.6$ y $p < 2,2 \times 10^{-16}$.

El modelo es globalmente significativo, es decir, el conjunto de variables *IPC*, *GH* y *PC* explica de manera significativa la variabilidad de *TUR*.

Interpretación del ANOVA:

Variable	F value	p-value	Interpretación
<i>IPC</i>	792.448	$< 2e - 16$	Mayor Contribución
<i>GH</i>	31.062	$5.56e - 07$	Contribución significativa
<i>PC</i>	84.432	$3.057e - 13$	Contribución significativa

Cuadro 12: Interpretación del ANOVA

IPC: Con un p-value de prácticamente cero y un F-valor 792.448, puede decirse que la variable es la que es más explicativa. Nos dice que el Índice de Precios al Consumidor es el principal motivo en los cambios del flujo turístico.

GH: Igualmente tiene un p-valor muy por debajo de 0.05 y un F-valor de 31.062, también tiene relevancia en el modelo, es útil para explicar cómo se comporta el turismo y el gasto en hospedaje aumenta el turismo.

PC: Así como las otras dos variables, tiene un p-valor bajo y un F-valor alto, por lo que contribuye al modelo y reafirma que el personal ocupado en comercio minorista afecta de manera significativa a la demanda turística.

5.4. Propuesta y justificación de los mejores modelos

Estandarizar variables sirve como una herramienta esencial para realizar una justa comparación equitativa entre variable que poseen unidades de medidas distintas, como son los índices y las tasas de inflación.

Cuando se transforman los datos a desviaciones estándar, se logra eliminar el sesgo que existía en la escala original y se logra ver claramente el peso de cada factor sobre el turismo. Esta especificación logró determinar una jerarquía de los pesos de las variables regresoras sobre la actividad turística que los modelos en otras unidades no permiten ver claramente.

Interpretación de los coeficientes de regresión:

Intercepto ($\beta_0 = 0$), cuando todas las variables regresoras tienen un valor de 0, entonces se espera que la actividad turística esté en su valor promedio.

IPC ($\beta_1 = 0.95776$), manteniendo todas las regresoras constantes, el incremento de una desviación estándar en el IPC aumenta 0.95776 desviaciones estándar en la actividad turística. Como es el más relevante significativamente, es el que mayor tiene peso en el cambio del turismo e impacto individual en el modelo. GH ($\beta_2 = 0.47397$), cuando se mantienen constantes, el aumento de una desviación estándar en el Gasto Hotelero, incrementa el turismo 0.47397 desviaciones estándar. El turismo es sensible al gasto y consumo de los turistas.

PC ($\beta_3 = -0.33766$), manteniendo constantes las demás variables, cuando se incrementa en una desviación estándar el PC, se reduce el turismo 0.33766 desviaciones estándar. Se confirma que a mayor personal ocupado, los turistas disminuyen.

6. Conclusiones

En el presente estudio se desarrollaron y evaluaron diversos modelos de Regresión Lineal Múltiple con el objetivo de explicar el comportamiento de la variable *TUR* a partir de un conjunto de variables económicas relevantes. Como primera etapa, se realizó un proceso de selección de variables utilizando criterios de información, particularmente *AIC* y *BIC*, los cuales permiten balancear la calidad de ajuste del modelo conforme a su complejidad.

Si bien ambos criterios cumplen esta función, su comportamiento es distinto. El *AIC* tiende a seleccionar modelos más complejos, ya que penaliza menos la inclusión de variables adicionales. Por otra parte, el *BIC* impone una penalización más fuerte, lo que favorece a modelos más simples. Como se vio en la práctica, al aplicar ambos criterios sobre el mismo conjunto de variables, se obtuvieron modelos diferentes: los seleccionados por *AIC* incluyeron mayor cantidad de regresoras, mientras que los seleccionados por *BIC* resultaron más reducidos. Permitiendo contar con alternativas a evaluar en próximas etapas.

Posteriormente, se llevó a cabo la verificación de los supuestos clásicos del modelo de regresión. En los modelos iniciales se detectaron problemas de heterocedasticidad y autocorrelación en los residuos, aunque se cumplían los supuestos de normalidad y media cero. Así mismo, no se identificaron problemas severos de multicolinealidad.

Mediante el análisis de residuos estudentizados, valores de apalancamiento y distancia de Cook, se identificaron observaciones atípicas e influyentes que afectaban la estabilidad del modelo. La eliminación de estos datos permitió obtener una versión limpia de cada modelo, en la cual se corrigió la heterocedasticidad y se mejoró el ajuste general, evidenciando un incremento en el coeficiente de determinación ajustado.

Este trabajo demuestra que, efectivamente, el turismo en México es altamente sensible al Índice de Precios al Consumidor (*IPC*) y Personal ocupado en Comercio minorista (*PC*). Sin embargo, el análisis revela que el Personal ocupado en Hoteles (*PH*) tiene un peso mucho menor de lo esperado comparado con los precios generales de la economía. En conclusión, el análisis permitió identificar modelos estadísticamente sólidos e interpretables, donde se describe de manera clara la relación entre el turismo y las variables económicas consideradas, destacando la importancia de la depuración de datos.