



Universidad de las Américas Puebla

Licenciatura en Actuaría

Proyecto de Regresión Logística

Materia: Econometría I

Profesor(a): Daniela Cortés Toto

Autores:

Karla Yunuen Fischer Juárez 180196

Claudia Verónica Montes Armas 181714

Shaiel Benet Morales Fortozo 181488

Puebla, México

2 de mayo de 2026

Índice

1. Introducción	1
2. Desarrollo	2
2.1. Base de datos	2
2.2. Elección de variables y verificación de supuestos	3
2.2.1. Lóticos	5
2.2.2. Lénticos	8
2.3. Estimación de parámetros y pruebas de significancia	11
2.3.1. Lóticos	11
2.3.2. Lénticos	15
2.4. Cálculo de probabilidades y cociente de posibilidades	18
2.4.1. Lóticos	18
2.4.2. Lénticos	19
3. Conclusión	21

1. Introducción

La preservación de la calidad del agua superficial es un eje fundamental para garantizar el derecho humano al agua y saneamiento en México. En este contexto, la Comisión Nacional del Agua (CONAGUA), a través de la Red nacional de medición de Calidad del Agua (RENAMECA), realiza un monitoreo sistemático y permanente de los cuerpos de agua en todo el país. este monitoreo analiza parámetros fisicoquímicos y microbiológicos para evaluar la salud de los ecosistemas acuáticos y su aptitud para distintos usos.

Se utilizan dos herramientas normativas para la interpretación de los datos:

- La NOM-001-SEMARNAT-2021: Esta establece los límites permisibles de contaminantes en las descargas de aguas residuales.
- El Semáforo de Calidad de Agua: Es una herramienta cuantitativa que clasifica los sitios de monitoreo en tres niveles de cumplimiento: Verde (excelente/ buena calidad), Amarillo (calidad aceptable/ intermedia) y Rojo (mala calidad/ incumplimiento). Esta clasificación se basa en indicadores clave como la Demanda Bioquímica (DBO), Sólidos Suspendidos Totales (SST) y Escherichia Coli (E-COLI).

El estado de Aguascalientes, ubicado en una zona con alta demanda hídrica, depende del manejo eficiente de sus cuerpos de agua superficiales, los cuales se dividen principalmente en sistemas lóticos (ríos y arroyos en movimiento constante) y lénticos (aguas estancadas como presas y embalses).

A pesar del cuidado de la RENAMECA, diversos factores antropológicos ponen en riesgo la calidad de estos cuerpos de agua. Por ello, el presente proyecto se enfoca en el desarrollo de un modelo de Regresión Logística para predecir el estado de cumplimiento ambiental en la entidad.

El problema consiste en evaluar y predecir la probabilidad de que un cuerpo de agua superficial (lóticos o lénticos) en el estado de Aguascalientes se encuentre en clasificación Semáforo Rojo.

Se puede resolver mediante una Regresión Logística ya que, el objetivo no es predecir un valor continuo de contaminación sino una clasificación categórica. La regresión logística está diseñada específicamente para modelar la probabilidad de pertenencia a una de las dos categóricas Rojo o No Rojo.

El proyecto requiere utilizar tanto variables numéricas (parámetros de la RENAMECA) como variables categóricas (el cumplimiento de la NOM-001-SEMARNAT-2021). La regresión logística permite integrar ambos tipos de regresoras para explicar el fenómeno.

Hipótesis del proyecto: Las variables de Coliformes Fecales (COLI_FEC) y Absorbancia UV (ABS_UV) si tienen un efecto significativo sobre la probabilidad de que un cuerpo de agua sea clasificado en Semáforo Rojo.

2. Desarrollo

2.1. Base de datos

La base de un modelo de regresión logística depende completamente de la veracidad de los datos a usar. Para este proyecto, el conjunto de datos seleccionados proviene directamente de RENAMECA, la cual es dirigida por la CONAGUA. Los datos corresponden al monitoreo de cuerpos de agua, todas recolectadas en diversos puntos geográficos y en momentos específicos. La base de datos descargada está compuesta por tres pestañas: Sitios, que tiene la información geográfica; Resultados, que tiene las mediciones temporales de los parámetros, y Simbología con el nombre completo de cada parámetro monitoreado.

Para asegurar la homogeneidad en el modelo, se aplicó un filtro en la pestaña de resultados para cumplir con las restricciones del estudio. Se mantuvieron los valores correspondientes a los cuerpos de agua superficiales, categorizados en:

- **Lóticos:** Cuerpos de agua que mantienen un movimiento predominantemente unidireccional y constante, como ríos, arroyos y canales.
- **Lénticos:** Masas de agua cerradas que no tienen movimiento, permanecen en un solo lugar sin fluir ni correr, entre estos se encuentran pantanos, lagos y lagunas.

Fueron excluidos las demás observaciones pertenecientes a sistemas subterráneos, costeros y humedales.

Para el modelo de regresión logística, la construcción de la variable respuesta (y) se realizó utilizando tres parámetros indicadores: Demanda Química de Oxígeno (DQO), Sólidos suspendidos Totales (SST) y *Escherichia coli* (E-COLI). Cada observación de cada uno de estos parámetros fue clasificado de forma individual como 'Cumple' o 'No cumple', de acuerdo a la tabla de clasificación establecida por la CONAGUA. Dado que, solamente DQO pertenece al primer campo del semáforo, el incumplimiento de este parámetro era suficiente para clasificar la observación como nivel rojo, independientemente del comportamiento de SST y E-COLI.

A partir de esto, la variable fue dicotomizada con enfoque en probabilidad de riesgo, donde el evento de interés, asignada con el valor 1, representa el incumplimiento normativo, mientras que el cumplimiento normativo tiene el valor de 0, facilitando la interpretación de contaminación:

$$Y_{(i)} = \begin{cases} 1 & \text{si el cuerpo de agua incumple la normativa (Rojo)} \\ 0 & \text{en otro caso (Amarillo/Verde)} \end{cases} \quad (1)$$

Ya que la base de datos presentaba valores faltantes en ciertos parámetros, el método que se consideró adecuado para la imputación de datos fue el método por K vecinos más cercanos (KNN, por sus siglas en inglés *K-Nearest Neighbors*) para preservar la mayor cantidad de observaciones posibles sin agregar sesgos por eliminación de registros incompletos (*listwise deletion*); es problemático al momento de crear bases de datos de monitoreo ambiental donde la falta de valores es frecuente gracias a las limitantes instrumentarias

o condiciones del entorno. Este método estima el valor que falta de una observación usando la proximidad para comprar un punto de datos con un conjunto de datos con el que se entrenó y los cuales memorizó para realizar predicciones, es un algoritmo simple e intuitivo, promedia los valores de los datos más cercanos a tu observación faltante y se los asigna. La similitud entre observaciones se puede medir con la distancia euclidiana, dada por la fórmula:

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2} \quad (2)$$

donde x_i es la observación con valor faltante, x_j es una observación propuesta a vecino, y p es el número de variables predictoras, x_{ik} es el valor de la variable k en la observación i , y x_{jk} es el valor de la variable k en la observación j . Ya una vez que se identificaron los K vecinos más cercanos, con $\mathcal{N}_K$ como el conjunto de los K vecinos más cercanos, el valor faltante se asigna como:

$$\hat{x}_j = \frac{1}{K} \sum_{i \in \mathcal{N}_K} x_{ij} \quad (3)$$

en otras palabras, es el promedio de los valores observados de esa variable entre los K vecinos más cercanos. En las variables dicotómicas, no se utiliza el promedio, en este caso se utiliza la moda, el valor más recurrente entre los K vecinos. En este trabajo, se uso $K = 5$, valor que es el más común, implementado en R mediante la función `knn()` de la librería `VIM` (*Visualization and Imputation of Missing Values*). El algoritmo se encarga de estandarizar las variables antes de realizar el cálculo de distancias, evitando que aquellas que tengan magnitudes mayores predominen sobre las otras y garantiza una justa comparación entre las variables del modelo.

Previo a la estimación de los modelos, se dividió la base de datos a través de una partición estratificada, siguiendo el método de validación cruzada simple. El conjunto de entrenamiento (*training set*) conforma el 80% de las observaciones totales y fue utilizado para estimar los parámetros, es donde el algoritmo de máxima verosimilitud estima los coeficientes β_i para cada una de las variables. El conjunto de prueba (*test set*) es el 20% restante de los datos, este se utiliza para validar el modelo donde el modelo ya está entrenado, con el fin de evitar sobreajuste y garantizar precisión. Para que los resultados puedan ser comprobables en toda ejecución, un muestreo aleatorio se usó para la partición. Esta se realizó de manera segmentada a través de la función `initial_split()`, parte de la librería `rsample`, donde se asegura que a proporción de cuerpos de agua $y = 1$ (Rojo) y $y = 0$ (Verde/Amarillo) sea similar en ambos conjuntos

Con esto se garantiza que la partición estratificada sea equiparable en ambos conjuntos, al mismo tiempo que la distribución original de la variable respuesta se mantiene.

2.2. Elección de variables y verificación de supuestos

El proceso de selección de variables en un modelo de regresión es un paso indispensable que establece la interpretabilidad y la capacidad predictiva. Sin embargo, en los modelos de regresión, existe la creencia

natural de que incluir la mayor cantidad de variables posibles mejoraría la capacidad predictiva del modelo. No obstante, en la práctica, la inclusión de variables irrelevantes puede generar problemas de sobreajuste (*overfitting*), donde el modelo predice de manera adecuada los datos de entrenamiento, pero no los datos nuevos; inflación de la varianza de los estimadores o crear problemas de multicolinealidad.

Tomando en cuenta que el principal objetivo de este trabajo es la predicción sobre un cuerpo de agua y su situación de incumplimiento se encuentra crítico, es de suma importancia alcanzar la parsimonia. En este proyecto, la selección del mejor modelo se realizó con base en dos criterios clave ampliamente usados: el Criterio de Información de Akaike (AIC por sus siglas en inglés *Akaike Information Criterion*) y el Criterio de Información Bayesiano (BIC por sus siglas en inglés *Bayesian Information Criterion*). En ambos casos, parten del valor de Máxima Verosimilitud (L), que recompensa al modelo por tener un buen ajuste a los datos, pero se penaliza la complejidad del modelo, es decir, la cantidad de parámetros estimados, con el fin de obtener un balance entre la parsimonia y el ajuste del modelo a los datos. La estructura general está dada por:

$$-2\ell(L) + \text{Penalización} \quad (4)$$

La regla final para la decisión es aquel que presente el menor valor de AIC o BIC.

- **Criterio de Información de Akaike (AIC):** El AIC está definido por:

$$\text{AIC} = -2\ell(\hat{\beta}) + 2p \quad (5)$$

en donde p es el número de parámetros del modelo y $\ell(\hat{\beta})$ es el valor de la log-verosimilitud evaluada en los parámetros estimados. Todo el término de $-2\ell(\hat{\beta})$ evalúa la falta de ajuste del modelo, mientras que $2p$ es la penalización por cada variable nueva.

- **Criterio de Información Bayesiano (BIC):** El BIC está definido por:

$$\text{BIC} = -2\ell(\hat{\beta}) + p \ln(n) \quad (6)$$

donde n es el tamaño de la muestra. A diferencia del AIC, que penaliza cada parámetro adicional con la constante 2, el BIC penaliza de manera más estricta conforme el tamaño de la muestra aumenta. Por esto mismo, el BIC tiende a seleccionar modelos más parsimoniosos que el AIC, de gran utilidad cuando hay un gran número de observaciones.

Para ambos modelos son comparables, solamente si se trabaja sobre el mismo conjunto de datos. Ambos criterios son propuestos para cada modelo, usando el que tenga menor valor como modelo ganador.

Los modelos se estimaron mediante máxima verosimilitud `glm()` con familia binomial y función logit. A partir del modelo, se aplicó la selección *stepwise* bidireccional buscando reducir el valor de AIC y BIC, donde se obtuvo dos modelos candidatos por tipo de cuerpo de agua.

2.2.1. Lóticos

Se definen las siguientes hipótesis para comparar el modelo con p parámetros frente al modelo reducido con $p - r$ parámetros:

$$H_0 : \beta_2 = 0 \quad \text{vs} \quad H_1 : \beta_2 \neq 0 \quad (7)$$

H_0 nos dice que las variables excluidas, E-Coli, COT, DQO TOT, SST, etc. no tienen un efecto significativo sobre la variable respuesta Y (Semáforo) en presencia de las demás variables.

Por otra parte H_1 , nos dice que al menos uno de los coeficientes de las variables excluidas es diferente de cero, por lo que su eliminación resulta en una pérdida significativa de información.

El estadístico de prueba se basa en la diferencia de las desviaciones de ambos modelos.

$$\lambda(\beta_2|\beta_1) = \lambda(\beta_1) - \lambda(\beta) \quad (8)$$

De acuerdo a el código, la desviación del modelo reducido ($\lambda(\beta_1)$): 249.2289

Y la desviación del modelo Completo ($\lambda(\beta)$): 1.9087×10^{-09} .

Por lo que, $\lambda(\beta_2|\beta_1) = 249.2289 - 1.9087 \times 10^{-09} = 249.2289$, con $r = 4$ grados de libertad (donde, $p=21$ y $p-r=17$).

Con un nivel de significancia del 0.05, el valor crítico $\chi_{0.05,4}^2 \approx 9.488$. Dado que $249.2289 > 9.488$, el estadístico cae en la región de rechazo y se rechaza la hipótesis nula, por lo tanto existe evidencia estadística suficiente para afirmar que el subconjunto de variables eliminadas aporta información significativa al modelo.

Las variables E_COLI, DQO y SST no se incluyeron como regresoras en el modelo debido a que forman parte de la construcción de la variable respuesta. Incluirlas como variables explicativas generaría problemas de especificación, al introducir información contenida directamente en la variable dependiente, lo cual sesgaría las estimaciones.

El modelo depurado es el siguiente:

$$\begin{aligned} y = & 4.88 - 0.38(\text{TOX_V_15}) - 0.96(\text{COLI_FEC}) - 0.60(\text{pH_CAMPO}) + 0.09(\text{TEMP_AGUA}) \\ & - 1.21(\text{COT}) - 1.64(\text{N_TOT}) - 0.16(\text{P_TOT}) + 0.003(\text{COLOR_VER}) + 1.49(\text{ABS_UV}) \\ & + 0.0008(\text{TURBIEDAD}) - 1.06(\text{AS_TOT}) - 0.97(\text{HG_TOT}) + 1.41(\text{PB_TOT}) \\ & + 0.0002(\text{DUR_TOT}) - 0.001(\text{CONDUCT_CAMPO}) - 0.002(\text{OD_PORC}) \end{aligned} \quad (9)$$

Con un AIC= 283.23 y una desviación Residual = 249.23.

Con el fin de obtener un modelo más parsimonioso, se aplicó un proceso de selección de variables y validación basado en el Criterio de Akaike (AIC) y pruebas de cumplimiento de supuestos.

A partir del modelo lógico depurado, se ejecutó el algoritmo *stepwise* en ambas direcciones para identificar la combinación de variables que minimizara el AIC. Este proceso resultó en el modelo lógico AIC,

el cual redujo la complejidad del modelo original manteniendo un equilibrio óptimo entre ajuste y número de predictores. El cual quedó de la siguiente manera:

$$y = -2.79 - 1.19(COLI_FEC) + 0.098(TEMP_AGUA) - 1.42(COT) - 1.29(N_TOT) + 0.004(COLOR_VER) + 1.48(ABS_UV) - 0.85(HG_TOT) + 1.72(PB_TOT) \quad (10)$$

Al evaluar el supuesto de linealidad en el logit mediante la prueba de Box-Tidwell, se observó que las variables COLOR_VER $Pr(> |t|) < 0.001$ y ABS_UV $Pr(> |t|) < 0.035$ rechazan la hipótesis nula de linealidad. Por lo que se procedió a transformar ambas variables utilizando sus estimadores de máxima verosimilitud (λ):

- COLOR_VER AIC trans= $(COLOR_VER)^{0.25695}$
- ABS UV AIC trans= $(ABS_UV)^{0.74388}$

Por lo cual, el modelo quedó de la siguiente manera:

$$y = -5.49 - 0.95(COLI_FEC) + 0.10(TEMP_AGUA) - 1.44(COT) - 1.20(N_TOT) + 0.87(COLOR_VER^{0.256}) + 1.70(ABS_UV^{0.743}) - 0.84(HG_TOT) + 1.71(PB_TOT) \quad (11)$$

Tras aplicar las transformaciones, se observó que la variable COLI_FEC perdió significancia estadística $Pr(> |z|) = 0.126$. Para validar su eliminación, se realizó una prueba de hipótesis sobre subconjuntos de parámetros mediante el cálculo de la desviación condicional (λ).

El estadístico calculado = 2.68 y el Valor Crítico ($\chi^2_{0.5,1}$) = 3.84. Dado que el estadístico (λ) fue menor al valor crítico, se aceptó la hipótesis nula, confirmando que la exclusión de COLI_FEC no penaliza significativamente la capacidad predictiva del modelo.

Por lo cual el modelo definitivo sin el COLOR_VER, la cual dejó de ser significativo tras las transformaciones.

$$y = -6.075 + 0.097(TEMP_AGUA) - 1.471(COT) - 1.081(N_TOT) + 0.990(COLOR_VER^{0.256}) + 1.889(ABS_UV^{0.743}) - 0.823(HG_TOT) + 1.750(PB_TOT) \quad (12)$$

Cuadro 1: Comparación de modelos logísticos mediante pseudo- R^2

Modelo	Cox-Snell	Nagelkerke	McFadden	Observaciones
1. Lógico Depurado	—	—	—	Modelo base con 16 variables.
2. Seleccionado AIC	0.4085	0.5570	0.3972	Simplificación por Stepwise.
3. Con Transformaciones	0.4128	0.5628	0.4027	Mejor ajuste estadístico tras corregir linealidad.
4. Final (Sin COLI_FEC)	0.4080	0.5560	0.3965	Modelo óptimo y parsimonioso.

Usando de ejemplo el modelo `_lot_AIC_trans`, se analizaron tres medidas de Pseudo R^2 que permiten cuantificar qué tanta información de la variable respuesta es explicada por los predictores.

- McFadden(0.3965): Este índice compara la mejora de la verosimilitud del modelo completo frente a un modelo nulo. De acuerdo con la literatura de modelo de respuesta binaria, un valor de 0.3965 indica un ajuste altamente satisfactorio, ya que valores situados entre 0.2 y 0.4 se considera excelente en el contexto de regresión logística.
- Nagelkerke (0.5560): Este estadístico ajusta la escala de la prueba para que pueda alcanzar un valor máximo de 1. El resultado 0.5560 sugiere que el modelo final explicar el 55.6 % de la variabilidad o incertidumbre asociada a la clasificación del semáforo entre los cuerpos de agua lóticos.
- Cox y Snell (0.4080): se interpreta como un R^2 generalizado. Este valor refleja que el modelo ajustado representa una mejora sustancial en la verosimilitud respecto al modelo nulo, manteniendo su equivalencia teórica con el coeficiente de determinación de la regresión lineal clásica.

Una vez que tenemos el modelo optimizado mediante el criterio AIC, se procedió a verificar el supuesto de no multicolinealidad entre las variables independientes. Este análisis es crucial para asegurar que la varianza de los coeficientes estimados no se encuentre inflada por correlaciones excesivas entre los predictores.

El Factor de Inflación (VIF) mide que tanto aumenta la varianza de un coeficiente de regresión a causa de la colinealidad con otras variables. En donde $VIF = 1$ significa que no existe correlación entre esta variable independiente y cualquier otra; $1 < VIF < 10$ sugiere una correlación moderada pero no es necesario resolverla; $VIF >$ son niveles críticos de multicolinealidad.

Cuadro 2: Valores del Factor de Inflación de la Varianza (VIF)

Variable	VIF
TEMP_AGUA	1.087
COT	1.515
N_TOT	1.280
COLOR_VER_AIC_trans	1.531
ABS_UV_AIC_trans	1.058
HG_TOT	1.065
PB_TOT	1.212

Concluimos que si todas las variables cumplen el supuesto de multicolinealidad.

Para evaluar el desempeño del modelo `_lot_AIC_trans` en la clasificación de los estados del semáforo, se realizó una evaluación mediante una matriz de confusión utilizando un conjunto de datos de prueba.

El modelo final demostró una lata eficiencia en la clasificación, con los siguientes indicadores clave:

- Exactitud (*Accuracy*): 83.13 % el modelo clasifica correctamente el estado del semáforo en más de 8 de cada 10 casos evaluados.

- Predicción Correctas: 83.13 % este corresponde a un 62.65 % de Verdaderos Negativos (semáforo 0 correctamente identificado) y un 20.38 % el Verdadero Positivos (semáforo 1 correctamente identificado).
- Falsos Positivos: 0 % el modelo presenta una especificidad del 100 %, lo que significa que un clasifica erróneamente un sitio limpio como contaminado.
- Falsos negativos: 16.87 % representa los casos donde el modelo predijo un estado 0 (limpio) cuando la realidad era un estado 1 (contaminado). Este margen de error se refleja en una Sensibilidad del 54.84 %.

La matriz de confusión revela que el modelo es extremadamente conservador y preciso en sus alertas positivas.

Se ejecutó un procedimiento de *stepwise* utilizando el Criterio de Información Bayesiano (BIC), el cual aplica una penalización más severa para cada variable añadida.

El modelo resultante excluyó variables como `ph_CAMPO` y requirió transformaciones de potencia en `COLOR_VER` ($\lambda = 0.236$) y `ABS_UV` ($\lambda = 0.707$) para corregir la falta de linealidad detectada por la prueba Box-Tidwell. Se calculó el VIF, confirmando valores inferiores a 1.6 en todos los predictores.

Para definir el modelo ganador, se contrastaron los valores de bondad de ajuste de ambos procedimientos:

Cuadro 3: Comparación entre el modelo seleccionado por AIC y el modelo BIC

Métrica	Modelo AIC (Elegido)	Modelo BIC
AIC	278.46	286.16
BIC	308.82	308.93

Se determinó que el modelo AIC es el mejor para este estudio. La decisión se fundamenta en que este modelo minimiza ambos criterios de información, ofreciendo el mejor balance entre complejidad y capacidad explicativa de la variabilidad del semáforo en los datos muestrales.

Para el modelo lógicos ganador, al reevaluar el modelo con las variables transformadas, la prueba de Box-Tidwell mostró valores de significancia altamente favorables, donde `COLOR_VER_AIC_trans`: $Pr(> |t|) = 0,9738$ y `ABS_UV_AIC_trans` $Pr(> |t|) = 0,9672$. Ya que, ambos valores son significativamente mayores a 0.05, se acepta la hipótesis nula de que existe una relación lineal entre estas variables transformadas y e logit de la respuesta.

2.2.2. Lénticos

Se definen las siguientes hipótesis para comparar el modelo con p parámetros frente al modelo reducido con $p - r$ parámetros:

$$H_0 : \beta_2 = 0 \quad \text{vs} \quad H_1 : \beta_2 \neq 0 \quad (13)$$

El estadístico de prueba se basa en la diferencia de las desviaciones de ambos modelos. De acuerdo a el código, la desviación del modelo reducido ($\lambda(\beta_1)$): 148.50, mientras que la del modelo completo ($\lambda(\beta)$): 8.8184×10^{-10} .

Por lo que, $\lambda(\beta_2|\beta_1) \approx 148.50$. Al igual que en el modelo de lóxicos se rechaza H_0 debido a que el estadístico supera ampliamente el valor crítico, confirmando que el subconjunto de variables aporta información significativa.

Sin embargo, las variables E_COLI, DQO y SST se excluyeron del proceso de modelado posterior porque forman parte de la construcción de la propia variable respuesta (semáforo), lo que generaría un sesgo de especificación. Asimismo, se eliminó P_TOT debido a que no presentaba variabilidad en los datos.

El modelo depurado inicial de lóxicos presentó un AIC= 182.5 y una desviación residual = 148.50. El modelo depurado quedo de la siguiente manera:

$$\begin{aligned} y = & 40.49 - 0.76(\text{COLI_FEC}) + 0.35(\text{pH_CAMPO}) - 0.39(\text{TEMP_AGUA}) - 2.92(\text{COT}) \\ & - 18.34(\text{DBO_TOT}) + 4.19(\text{N_TOT}) - 0.002(\text{COLOR_VER}) - 0.03(\text{TRANSPARENCIA}) \\ & + 3.15(\text{ABS_UV}) - 0.003(\text{TURBIEDAD}) - 1.06(\text{AS_TOT}) - 0.35(\text{HG_TOT}) \\ & - 17.68(\text{PB_TOT}) + 0.02(\text{DUR_TOT}) - 0.001(\text{CONDUCT_CAMPO}) + 0.02(\text{OD_PORC}) \end{aligned} \quad (14)$$

Para obtener un modelo más parsimonioso, se aplicó un proceso de selección *stepwise* en ambas direcciones basado en el Criterio de Akaike (AIC). El modelo resultante fue el siguiente:

$$\begin{aligned} y = & 42.34 - 0.38(\text{TEMP_AGUA}) - 18.87(\text{DBO_TOT}) + 2.13(\text{ABS_UV}) \\ & - 17.87(\text{PB_TOT}) + 0.024(\text{DUR_TOT}) + 0.027(\text{OD_PORC}) \end{aligned} \quad (15)$$

Este modelo alcanzó un AIC= 167.29 con una desviación= 153.29. Al evaluar el supuesto de linealidad en el logit mediante la prueba de Box-Tidwell, se observó que la variable DUR_TOT rechazaba la hipótesis de linealidad, $Pr(> |t|) = 0.0019$. Por lo tanto, se aplicó una transformación utilizando un estimador de máxima verosimilitud: (λ):

$$\blacksquare \text{ DUR_TOT AIC trans} = (\text{DUR_TOT})^{0.133289}$$

Tras las pruebas de hipótesis sobre subconjuntos de parámetros, se determinó que la variable ABS_UV no era estadísticamente significativa ($\lambda_{uv} = 2.68$), valor crítico $\chi^2_{0.05,1} = 3.84$. Por el contrario, se demostró que DBO_TOT y PB_TOT no podían ser eliminadas simultáneamente sin perder capacidad explicativa. Por lo cual, el modelo transformado y final quedó de la siguiente manera:

$$y = 34.42 - 0.408(\text{TEMP_AGUA}) - 19.00(\text{DBO_TOT}) + 6.38(\text{DUR_TOT}^{0.133}) + 0.025(\text{OD_PORC}) \quad (16)$$

Usando de ejemplo el modelo de lóxicos transformado de AIC, se analizaron tres medidas de Pseudo R^2 que permiten cuantificar qué tanta información de la variable respuesta es explicada por los predictores.

Cuadro 4: Comparación de modelos logísticos lénticos mediante pseudo- R^2

Modelo	Cox-Snell	Nagelkerke	McFadden
Seleccionado AIC	0.3049	0.4085	0.2651
Final (Con transformaciones y sin ABS_UV)	0.2960	0.3965	0.2558

- McFadden(0.2558): Indica un ajuste satisfactorio y excelente para modelos de regresión logística ambiental.
- Nagelkerke (0.3965): Sugiere que el modelo explica 39.65 % de la variabilidad en la clasificación de semáforo.
- Cox y Snell (0.2960): Refleja una mejora sustancial respecto al modelo nulo.

Una vez que tenemos el modelo optimizado mediante el criterio AIC, se procedió a verificar el supuesto de no multicolinealidad entre las variables independientes.

Cuadro 5: Valores del Factor de Inflación de la Varianza (VIF) para el modelo léntico

Variable	VIF
TEMP_AGUA	1.007
DBO_TOT	1.000
PB_TOT	1.000
DUR_TOT_AIC_trans	1.040
OD_PORC	1.045

Como todas las variables encuentran sumamente cercanas a 1, se asegura que no hay varianza inflada por correlaciones.

Para evaluar el desempeño del modelo $_{lot_AIC_trans}$ en la clasificación de los estados del semáforo, se realizó una evaluación mediante una matriz de confusión utilizando un conjunto de datos de prueba:

- Exactitud (*Accuracy*): 61.54 % el modelo clasifica correctamente el estado del semáforo en más de 6 de cada 10 casos evaluados.
- Predicción Correctas: 61.54 % este porcentaje se descompone en dos partes, un 35.89 % de Verdaderos Negativos (semáforo 0 correctamente identificado) y un 25.64 % de Verdaderos Positivos (semáforo 1 correctamente identificado).
- Falsos Positivos: 7.69 % el modelo presenta una especificidad del 82.35 %. Esto indica que el modelo es bastante confiable al declarar que un sitio está limpio, minimizando el error de dar falsas alarmas de contaminación en lugares que cumplen con la normativa.
- Falsos negativos: 30.77 % este valor representa los casos donde el modelo predijo un estado 0 (limpio) cuando la realidad física era un estado 1 (contaminado). Este margen de error se traduce en una sensibilidad del 45.45 %.

La matriz de confusión revela que el modelo es altamente preciso en sus alertas positivas, pero tiende a ser omiso ante ciertos eventos de contaminación, prefiriendo clasificar sitios dudosos como limpios antes que generar alertas erróneas.

Se ejecutó un procedimiento de *stepwise* utilizando el Criterio de Información Bayesiano (BIC).

El modelo resultante fue más parsimonioso, incluyendo únicamente las variables TEMP_AGUA, DBO_TOT y DUR_TOT. Al igual que en el procedimiento anterior, se detectó una falta de linealidad en la variable de dureza, por lo que se aplicó una transformación de potencia ($\lambda = 0,11728$) para corregir el supuesto de Box-Tidwell. Tras la transformación, se verificó el cumplimiento de la no multicolinealidad con el VIF cercanos a 1.

Para definir el modelo ganador, se contrastaron los valores de bondad de ajuste de ambos procedimientos:

Cuadro 6: Comparación entre el modelo seleccionado por AIC y el modelo BIC

Métrica	Modelo AIC (Elegido)	Modelo BIC
AIC	167.23	169.61
BIC	185.37	181.71

Se determinó que el modelo AIC es el mejor para este estudio. Ya que el modelo AIC minimiza el valor del Criterio de Akaike, lo que indica un mejor balance entre la complejidad del modelo y su ajuste a los datos. Y presenta coeficientes de determinación consistentemente más altos en todas las métricas de Pseudo- R^2 , lo que nos indica que logra capturar mayor proporción de la variabilidad del semáforo en los cuerpos de agua lénticos.

Para el modelo ganador, en este caso AIC, se validó el supuesto de linealidad mediante la prueba de BOX-Tidwell. Los resultados mostraron lo siguiente: El valor de significancia para la variable transformada fue de $Pr(> |t|)=0.9718$. Al ser un valor mucho mayor a 0.05, se aceptó la hipótesis nula de linealidad.

2.3. Estimación de parámetros y pruebas de significancia

2.3.1. Lógicos

Como ya fue mencionado, la estimación de los parámetros se realizó mediante el método de Máxima Verosimilitud. Se presentan los coeficientes estimados ($\hat{\beta}$) para los modelos ganadores en ambos cuerpos de agua.

1. Modelo 1: AIC. Se obtuvieron los siguientes coeficientes para el entrenamiento.

Cuadro 7: Coeficientes del Modelo AIC (Original)

Variable	Estimación ($\hat{\beta}$)	Error Est.	Valor z	Pr(> z)
(Intercepto)	-2.7960	1.7019	-1.643	0.1004
COLI_FEC	-1.1998	0.6110	-1.964	0.0496 *
TEMP_AGUA	0.0981	0.0496	1.979	0.0478 *
COT	-1.4260	0.5655	-2.522	0.0117 *
N_TOT	-1.2982	0.3793	-3.423	0.0006 ***
COLOR_VER	0.0041	0.0018	2.226	0.0260 *
ABS_UV	1.4841	0.5623	2.639	0.0083 **
HG_TOT	-0.8527	0.3530	-2.416	0.0157 *
PB_TOT	1.7213	0.8663	1.987	0.0469 *

Con los valores de esta tabla, se plantea la siguiente ecuación de regresión logística en términos del logit:

$$\ln\left(\frac{\hat{p}}{1-\hat{p}}\right) = -2.80 - 1.20 \cdot \text{COLI_FEC} + 0.10 \cdot \text{TEMP_AGUA} \\ - 1.43 \cdot \text{COT} - 1.30 \cdot \text{N_TOT} + 0.004 \cdot \text{COLOR_VER} \\ + 1.484 \cdot \text{ABS_UV} - 0.852 \cdot \text{HG_TOT} + 1.72 \cdot \text{PB_TOT} \quad (17)$$

En las pruebas de significancia individual, el *summary* indica que la variable asociada al Nitrógeno Total es altamente significativa ($p < 0.001$). La Absorción UV resultó muy significativa ($p < 0.01$), mientras que el Carbono Orgánico Total, Color Verdadero, Plomo Total, Mercurio Total, Temperatura del Agua y Coliformes Fecales son significativas a un nivel de $p < 0.05$. En la prueba global, el modelo reduce la *Null Deviance* de 434.92 a una *Residual Deviance* de 262.19, probando que la inclusión de estas regresoras mejora significativamente el ajuste del modelo.

El intercepto $\beta_0 = -2.8$ representa el *log-odds* cuando las variables explicativas valen 0; la probabilidad del evento es de aproximadamente 5.7 %. Se observa que *COLI_FEC* tiene un gran efecto negativo, ya que por cada incremento en una unidad reduce los odds aproximadamente un 70 %. De manera parecida, *COT* y *N_TOT* disminuyen los odds aproximadamente 76 % y 73 % respectivamente, mientras que *HG_TOT* los disminuye un 57 %. En la otra mano, *TEMP_AGUA* aumenta los odds en aproximadamente 10.5 %, y *COLOR_VER* tiene un efecto positivo bastante bajo, aproximadamente de 0.4 %. *ABS_UV* y *PB_TOT* multiplican los odds en aproximadamente 4.4 y 5.6 veces respectivamente, siendo las variables con mayor impacto en el modelo.

2. Modelo 2: AIC con transformaciones. Se obtuvieron los siguientes coeficientes para el entrenamiento:

Partiendo de los valores de esta tabla, se plantea la ecuación de regresión logística en términos del logit:

$$\ln\left(\frac{\hat{p}}{1-\hat{p}}\right) = -6.075 + 0.097 \cdot \text{TEMP_AGUA} - 1.471 \cdot \text{COT} - 1.081 \cdot \text{N_TOT} \\ + 0.991 \cdot \text{COLOR_VER_trans}^{0.26} + 1.889 \cdot \text{ABS_UV_trans}^{0.74} \\ - 0.824 \cdot \text{HG_TOT} + 1.750 \cdot \text{PB_TOT} \quad (18)$$

Cuadro 8: Coeficientes del Modelo AIC (Transformaciones)

Variable	Estimación ($\hat{\beta}$)	Error Est.	Valor z	Pr(> z)
(Intercepto)	-6.07502	2.21581	-2.742	0.0061 **
TEMP_AGUA	0.09713	0.04994	1.945	0.0517 .
COT	-1.4715	0.56018	-2.627	0.0086 **
N_TOT	-1.08108	0.37030	-2.919	0.0035 **
COLOR_VER_trans	0.99079	0.29753	3.330	0.0008 ***
ABS_UV_trans	1.88946	0.61376	3.079	0.0020 **
HG_TOT	-0.82394	0.35365	-2.330	0.0198 *
PB_TOT	1.75020	0.83072	2.107	0.0351 *

En las pruebas de significancia individual, el *summary* indica que las variables asociadas al Color Verdadero, Absorción UV, Nitrógeno Total y Carbono Orgánico Total son altamente significativas ($p < 0,001$). Plomo Total y Mercurio Total resultaron significativas ($p < 0,01$) mientras que Temperatura del Agua es significativa a un nivel más bajo ($p < 0,05$). En la prueba global, el modelo indica que reduce la *Null Deviance* de 434.92 a una *Residual Deviance* de 262.46, probando que incluir estas regresoras ayuda a mejorar de manera significativa el ajuste global del modelo

El intercepto $\beta_0 = -6.075$ muestra el *log-odds* cuando las demás variables explicativas valen 0; la probabilidad de que ocurra es de 0.23 %, prácticamente nula. Con *COT*, *N_TOT* y *HG_TOT* tienen efectos negativos un incremento en *COT* reduce los odds en aproximadamente 77 %, mientras que *N_TOT* los disminuye en alrededor de 66 % y *HG_TOT* en cerca de 56 %. Por otra parte, *TEMP_AGUA* tiene un efecto positivo moderado, incrementando los odds en aproximadamente 10.2 %. Sobre las variables transformadas, *COLOR_VER_trans*^{0,26} aumenta los odds aproximadamente 2.7 veces, mientras que *ABS_UV_trans*^{0,74} tiene mayor repercusión, multiplicándolos en aproximadamente 6.6 veces. Por último, *PB_TOT* tiene un efecto positivo aumentando los odds aproximadamente 5.75 veces.

3. Modelo 3: BIC. Se obtuvieron los siguientes resultados para el entrenamiento:

Cuadro 9: Coeficientes del Modelo BIC (Original)

Variable	Estimación ($\hat{\beta}$)	Valor z	Pr(> z)
(Intercepto)	9.2173	2.944	0.0032 **
pH_CAMPO	-1.1275	-2.900	0.0037 **
N_TOT	-1.6065	-4.969	0.0000 ***
COLOR_VER	0.0043	2.843	0.0045 **
ABS_UV	1.6863	2.919	0.0035 **
AS_TOT	-0.7992	-2.437	0.0148 *
HG_TOT	-1.0039	-2.968	0.0030 **

Con los valores de esta tabla, se plantea la ecuación de regresión logística en términos logit:

$$\ln\left(\frac{\hat{p}}{1-\hat{p}}\right) = 9.217 - 1.127 \cdot pH_CAMPO - 1.606 \cdot N_OT + 0.0043 \cdot COLOR_VER + 1.686 \cdot ABS_UV - 0.799 \cdot AS_TOT - 1.003 \cdot HG_TOT \quad (19)$$

En las pruebas de significancia individual, el *summary* indica que la variable asociada al Nitrógeno Total es altamente significativa ($p < 0.001$). Las variables de Potencial de Hidrógeno, Color Verdadero, Absorción UV y Mercurio Total resultaron muy significativas ($p < 0.01$), mientras que el Arsénico Total es significativa a un nivel de $p < 0.05$. En la prueba global, el modelo indica una reducción de la *Null Deviance* de 434.92 a una *Residual Deviance* de 268.92, demostrando que la inclusión de estas regresoras ayuda a mejorar de manera significativa el ajuste global del modelo.

En el intercepto $\beta_0 = 9,217$ representa el *log_odds* cuando las demás variables vale 0; la probabilidad de que ocurra es de aproximadamente 99,99 %, el evento es casi seguro en el escenario base. Se observa que *pH_CAMPO*, *N_OT*, *AS_TOT* y *HG_TOT* tienen efectos negativos importantes: un incremento en *pH_CAMPO* reduce los odds en aproximadamente 68 %, mientras que *N_TOT* los disminuye en cerca de 80 %. Asimismo, *AS_TOT* reduce los odds en aproximadamente 55 % y *HG_TOT* en alrededor de 63 %. Por otro lado, *ABS_UV* presenta un efecto positivo fuerte, multiplicando los odds en aproximadamente 5.4 veces, mientras que *COLOR_VER* tiene un efecto positivo pero muy pequeño, incrementando los odds en aproximadamente 0,43 %.

4. Modelo 4: BIC con transformaciones. Se obtuvieron los siguientes resultados del modelo de entrenamiento.

Cuadro 10: Coeficientes del Modelo BIC (Transformaciones)

Variable	Estimación ($\hat{\beta}$)	Valor z	Pr(> z)
(Intercepto)	-2.8014	-2.589	0.0096 **
N_TOT	-1.6298	-5.102	0.0000 ***
COLOR_VER_BIC_trans	1.0965	3.690	0.0002 ***
ABS_UV_BIC_trans	2.1492	3.579	0.0003 ***
AS_TOT	-0.6393	-2.001	0.0453 *
HG_TOT	-0.9120	-2.722	0.0065 **

Partiendo con los valores de esta tabla, se plantea se plantea la ecuación de regresión logística en términos del logit:

$$\ln\left(\frac{\hat{p}}{1-\hat{p}}\right) = -2.801 - 1.629 \cdot N_TOT + 1.096 \cdot COLOR_VER_BIC_trans + 2.149 \cdot ABS_UV_BIC_trans - 0.639 \cdot AS_TOT - 0.912 \cdot HG_TOT \quad (20)$$

En las pruebas de significancia individual, el *summary* indica que las variables asociadas al Nitrógeno Total, Color Verdadero (transformado) y Absorción UV (transformada) son altamente significativas ($p < 0.001$). El Mercurio Total resultó muy significativa ($p < 0.01$), mientras que el Arsénico Total

es significativa ($p < 0.05$). En la prueba global, el modelo reduce la *Null Deviance* de 434.92 a una *Residual Deviance* de 274.16, probando que incluir estas regresoras ayuda a mejorar de manera significativa el ajuste global del modelo.

En el intercepto $\beta_0 = -2.801$ representa el *log-odds* cuando las demás variables vale 0; la probabilidad de que ocurra es de aproximadamente 5,7 %. Se observa que *N_TOT*, *AS_TOT* y *HG_TOT* tienen efectos negativos: un incremento en *N_TOT* reduce los odds en aproximadamente 80 %, mientras que *AS_TOT* los disminuye en cerca de 47 % y *HG_TOT* en alrededor de 60 %. Por otro lado, las variables transformadas *COLOR_VER_BIC_trans* y *ABS_UV_BIC_trans* presentan efectos positivos importantes: *COLOR_VER_BIC_trans* multiplica los odds en aproximadamente 3 veces, mientras que *ABS_UV_BIC_trans* los incrementa en aproximadamente 8.6 veces, siendo la variable con mayor impacto en el modelo.

2.3.2. Lénticos

Análogamente, fue utilizado el método de Máxima Verosimilitud. Se presentan los coeficientes estimados ($\hat{\beta}$) para los modelos ganadores en ambos cuerpos de agua.

- Modelo 1: AIC. A través del *summary* se obtuvo lo siguiente:

Cuadro 11: Coeficientes y significancia individual para el modelo AIC Léntico

Variable	Estimación ($\hat{\beta}$)	Error Est.	Valor z	Pr(> z)
(Intercepto)	42.34	3255.00	0.013	0.9896
TEMP_AGUA	-0.383	0.1328	-2.884	0.0039 **
DBO_TOT	-18.87	1664.00	-0.011	0.9910
ABS_UV	2.134	1.3450	1.586	0.1127
PB_TOT	-17.87	2797.00	-0.006	0.9949
DUR_TOT	0.02457	0.0070	3.509	0.0004 ***
OD_PORC	0.02736	0.0134	2.041	0.0413 *

A partir de los resultados obtenidos, se plantea la ecuación de regresión logística estimada en términos del logit para cuerpos lénticos:

$$\ln\left(\frac{\hat{p}}{1-\hat{p}}\right) = 42,34 - 0,383 \cdot \text{TEMP_AGUA} - 18,87 \cdot \text{DBO_TOT} + 2,134 \cdot \text{ABS_UV} - 17,87 \cdot \text{PB_TOT} + 0,024 \cdot \text{DUR_TOT} + 0,027 \cdot \text{OD_PORC} \quad (21)$$

En las pruebas de significancia individual, el *summary* indica que la variable asociada a la Dureza Total es altamente significativa ($p < 0.001$). La Temperatura del Agua resultó muy significativa ($p < 0.01$), mientras que el Oxígeno Disuelto es significativo ($p < 0.05$). En la prueba global, el modelo reduce la *Null Deviance* de 208.58 a una *Residual Deviance* de 153.29, probando que incluir estas regresoras ayuda a mejorar de manera significativa el ajuste global del modelo.

En el intercepto, $\beta_0 = 42,34$ representa el *log-odds* cuando las demás variables valen 0; dado el valor extremo positivo, la probabilidad de que ocurra el evento en el punto base es de aproximadamente

el 100 %. Se observa que $TEMP_AGUA$, DBO_TOT y PB_TOT tienen efectos negativos: un incremento unitario en la temperatura del agua reduce los *odds* en aproximadamente un 31,8 %, mientras que la Demanda Bioquímica de Oxígeno y el Plomo Total presentan coeficientes negativos que disminuyen las posibilidades de riesgo de manera drástica en este conjunto de datos. Por otro lado, las variables ABS_UV , DUR_TOT y OD_PORC presentan efectos positivos: la Dureza Total incrementa los *odds* en un 2.5 % por cada unidad y el Oxígeno Disuelto los eleva en un 2.8 %. Finalmente, la Absorción UV incrementa los *odds* en aproximadamente 8.4 veces ($e^{2,134}$), siendo la variable con el mayor impacto positivo en la probabilidad de clasificación en Semáforo Rojo para este modelo léntico.

- Modelo 2: AIC con transformaciones. Se obtuvieron los siguientes valores:

Cuadro 12: Coeficientes de Regresión Logística: Modelo AIC Transformado (Lénticos)

Variable	Estimación ($\hat{\beta}$)	Valor z	Pr(> z)
(Intercepto)	34.4236	0.011	0.9915
TEMP_AGUA	-0.4086	-3.081	0.0021 **
DBO_TOT	-19.0056	-0.011	0.9909
PB_TOT	-17.8284	-0.006	0.9949
DUR_TOT_AIC_trans	6.3856	3.566	0.0004 ***
OD_.	0.0251	1.932	0.0533 .

A partir de los resultados obtenidos, se plantea la ecuación de regresión logística estimada en términos del logit para cuerpos lénticos:

$$\ln\left(\frac{\hat{p}}{1-\hat{p}}\right) = 34,423 - 0,408 \cdot TEMP_AGUA - 19,005 \cdot DBO_TOT + -17,828 \cdot PB_TOT + 6,385 \cdot DUR_TOT_AIC_trans + 0,025 \cdot OD_ . \quad (22)$$

En las pruebas de significancia individual, el *summary* indica que la variable asociada a la Dureza Total transformada es altamente significativa ($p < 0,001$). La Temperatura del Agua resultó muy significativa ($p < 0,01$), mientras que el Oxígeno Disuelto presenta una significancia marginal ($p < 0,1$). En la prueba global, el modelo reduce la *Null Deviance* de 208.58 a una *Residual Deviance* de 155.23, probando que incluir estas regresoras ayuda a mejorar de manera significativa el ajuste global del modelo respecto al modelo nulo.

En el intercepto, $\beta_0 = 34,42$ representa el *log-odds* cuando las demás variables valen 0; dado el valor positivo extremo, la probabilidad de riesgo base en este punto es prácticamente del 100 %. Se observa que $TEMP_AGUA$, DBO_TOT y PB_TOT tienen efectos negativos: un incremento unitario en la temperatura del agua reduce los *odds* de riesgo en aproximadamente un 33.5 % ($e^{-0,408} \approx 0,665$). Por otro lado, la variable transformada $DUR_TOT_AIC_trans$ presenta un efecto positivo masivo: multiplica los *odds* en aproximadamente **593 veces** ($e^{6,385}$), siendo el factor con mayor impacto y peso predictivo en el ecosistema léntico analizado. Finalmente, el Oxígeno Disuelto incrementa las posibilidades de riesgo en un 2.5 % por cada unidad porcentual de saturación detectada.

- Modelo 3: BIC. Los valores resultantes fueron los siguientes:

Cuadro 13: Coeficientes de Regresión Logística: Modelo BIC Léntico

Variable	Estimación ($\hat{\beta}$)	Valor z	Pr(> z)
(Intercepto)	28.5608	0.029	0.9767
TEMP_AGUA	-0.4581	-3.388	0.0007 ***
DBO_TOT	-18.0784	-0.018	0.9853
DUR_TOT	0.0201	3.289	0.0010 **

Partiendo de estos resultados, la ecuación de regresión logística estimada en términos del logit para cuerpos lénticos:

$$\ln\left(\frac{\hat{p}}{1-\hat{p}}\right) = 28,56 - 0,458 \cdot \text{TEMP_AGUA} - 18,078 \cdot \text{DBO_TOT} + 0,02 \cdot \text{DUR_TOT} \quad (23)$$

En las pruebas de significancia individual, el *summary* indica que la variable asociada a la Temperatura del Agua es altamente significativa ($p < 0,001$), mientras que la Dureza Total resultó muy significativa ($p < 0,01$). En la prueba global, el modelo reduce la *Null Deviance* de 208.58 a una *Residual Deviance* de 164.48, confirmando que estas regresoras mejoran significativamente el ajuste respecto al modelo nulo.

En el intercepto, $\beta_0 = 28.56$ representa el *log-odds* base cuando las demás variables valen cero. Se observa que la *TEMP_AGUA* y la *DBO_TOT* tienen efectos negativos: un incremento en la temperatura reduce los *odds* de riesgo en aproximadamente un 36.8 % ($e^{-0.458} \approx 0.632$). Por otro lado, la Dureza Total presenta un efecto positivo, incrementando las posibilidades de clasificación en rojo en un 2 % por cada unidad de CaCO_3/L adicional.

- Modelo 4: BIC. Se obtuvieron los siguientes valores:

Cuadro 14: Coeficientes de Regresión Logística: Modelo BIC Transformado (Lénticos)

Variable	Estimación ($\hat{\beta}$)	Valor z	Pr(> z)
(Intercepto)	18.0693	0.018	0.9854
TEMP_AGUA	-0.4612	-3.401	0.0007 ***
DBO_TOT	-18.0622	-0.018	0.9854
DUR_TOT_BIC_trans	7.3624	3.589	0.0003 ***

Con estos valores, se construye la ecuación de regresión logística estimada en términos del logit para cuerpos lénticos:

$$\ln\left(\frac{\hat{p}}{1-\hat{p}}\right) = 18,069 - 0,461 \cdot \text{TEMP_AGUA} - 18,062 \cdot \text{DBO_TOT} + 7,362 \cdot \text{DUR_TOT_BIC_trans} \quad (24)$$

En las pruebas de significancia individual, el *summary* indica que las variables asociadas a la Temperatura del Agua y la Dureza Total transformada son altamente significativas ($p < 0,001$). En la prueba global, el modelo reduce la *Null Deviance* de 208.58 a una *Residual Deviance* de 163.66, lo que confirma que el modelo propuesto tiene un ajuste superior al modelo nulo para predecir el riesgo

hídrico.

Respecto a los coeficientes, se observa que la $TEMP_AGUA$ mantiene un efecto negativo, donde un incremento unitario reduce los *odds* de riesgo en aproximadamente un 36.9 % ($e^{-0.461} \approx 0.631$). Por el contrario, la variable $DUR_TOT_BIC_trans$ presenta un impacto masivo y positivo, multiplicando el cociente de posibilidades de Semáforo Rojo en aproximadamente ****1,575 veces**** ($e^{7.362}$), consolidándose como el principal factor de riesgo en presas y embalses bajo este criterio.

2.4. Cálculo de probabilidades y cociente de posibilidades

2.4.1. Lóticos

Bajo la condición *ceteris paribus*, se identifica a las siguientes variables como las principales causas de riesgo.

- Absorción UV Transformada ($\hat{\beta} = 1.8895$)

- Variación de una unidad ($\Delta X' = +1.0$ unidades en escala transformada)

$$e^{1.8895 \times 1.0} = 6.616 \quad (25)$$

Cada incremento de 1.0 unidad en la escala de potencia de la Absorción UV multiplica las posibilidades de Semáforo Rojo por 6.616 veces. La probabilidad de riesgo aumenta de 6.43 % a 31.26 %, es decir, 24.83 puntos porcentuales adicionales.

- Variación negativa ($\Delta X' = -1.0$ unidades en escala transformada)

$$e^{1.8895 \times -1.0} = 0.151 \quad (26)$$

Una disminución de 1.0 unidad en la escala transformada reduce las posibilidades de riesgo en un 84.9 %. La probabilidad cae de 6.43 % a 1.03 %.

- Color Verdadero Transformado ($\hat{\beta} = 0.9908$)

- Variación de una unidad ($\Delta X' = +1.0$ unidades en escala transformada)

$$e^{0.9908 \times 1.0} = 2.694 \quad (27)$$

Un incremento de 1.0 unidad en la escala de potencia del Color Verdadero multiplica las posibilidades de Semáforo Rojo por 2.694 veces. La probabilidad aumenta de 6.43 % a 15.62 %, un incremento de 9.19 puntos porcentuales.

- Variación negativa ($\Delta X' = -1.0$ unidades en escala transformada)

$$e^{0.9908 \times -1.0} = 0.371 \quad (28)$$

Una disminución de 1.0 unidad reduce las posibilidades en un 62.9 %. La probabilidad cae de 6.43 % a 2.49 %, una reducción de 3.94 puntos porcentuales.

- Temperatura del Agua ($\hat{\beta} = 0.0971$)
 - Variación de una unidad ($\Delta X = +1.0$ °C)

$$e^{0.0971 \times 1.0} = 1.102 \quad (29)$$

Un incremento de 1.0 °C en la temperatura aumenta las posibilidades de riesgo en un 10.2 %. La probabilidad varía de 6.43 % a 7.04 %, un cambio marginal de 0.61 puntos porcentuales.

- Variación negativa ($\Delta X = -1.0$ °C)

$$e^{0.0971 \times -1.0} = 0.907 \quad (30)$$

Una disminución de 1.0 °C reduce las posibilidades de riesgo en un 9.3 %. La probabilidad pasa de 6.43 % a 5.87 %.

Cuadro 15: Cálculo de variaciones en el cociente de posibilidades - Lóticos

Variable ($\hat{\beta}$)	Variación (ΔX)	Cociente ($e^{\beta \Delta X}$)	Impacto en el Riesgo	Probabilidad
Absorción UV (1,8895)	+1,0 unid.	6,616	×6,616 veces	31,26 %
	-1,0 unid.	0,151	-84,9 %	1,03 %
Color Verdadero (0,9908)	+1,0 unid.	2,694	+169,4 %	15,62 %
	-1,0 unid.	0,371	-62,9 %	2,49 %
Temperatura (0,0971)	+1,0 °C	1,102	+10,2 %	7,04 %
	-1,0 °C	0,907	-9,3 %	5,87 %
Probabilidad base (valores medios): $P_0 = 6,43$ %				

2.4.2. Lénticos

En el caso de los cuerpos de agua estancados, la dinámica de riesgo es altamente sensible a los cambios térmicos y a la dureza.

- Dureza Total Transformada ($\hat{\beta} = 6.3856$)
 - Variación de una unidad ($\Delta X = +1.0$):

$$e^{6.3856 \times 1.0} = 593.08 \quad (31)$$

El incremento de 1.0 unidad en la escala de potencia de dureza multiplica las posibilidades de Semáforo Rojo por 593.08 veces. La probabilidad escala de 88.95 % a 99.98 %, un incremento de 11.03 puntos porcentuales.

- Variación negativa ($\Delta X = -1.0$):

$$e^{6.3856 \times -1.0} = 0.00169 \quad (32)$$

Una disminución de 1.0 unidad reduce drásticamente las posibilidades de riesgo en un 99.83 %. La probabilidad colapsa de 88.95 % a 1.34 %, una caída de 87.61 puntos porcentuales.

■ Temperatura del Agua ($\hat{\beta} = -0.4086$)

- Variación de una unidad ($\Delta X = +1.0$ °C):

$$e^{-0.4086 \times 1.0} = 0.664 \quad (33)$$

El aumento de 1.0 °C en la temperatura disminuye las posibilidades de Semáforo Rojo en un 33.6 %. La probabilidad pasa de 88.95 % a 84.25 %, una reducción de 4.70 puntos porcentuales.

- Variación negativa ($\Delta X = -1.0$ °C):

$$e^{-0.4086 \times -1.0} = 1.505 \quad (34)$$

Una disminución de 1.0 °C incrementa las posibilidades de riesgo en un 50.5 %. La probabilidad aumenta de 88.95 % a 92.37 %, un incremento de 3.42 puntos porcentuales.

■ Oxígeno Disuelto ($\hat{\beta} = 0.0251$)

- Variación de una unidad ($\Delta X = +1.0$ %)

$$e^{0.0251 \times 1.0} = 1.0254 \quad (35)$$

Un aumento del 1.0 % en la saturación de oxígeno incrementa las posibilidades de riesgo en un 2.54 %. La probabilidad varía marginalmente de 88.95 % a 89.19 %, un incremento de 0.24 puntos porcentuales.

- Variación negativa ($\Delta X = -1.0$ %)

$$e^{0.0251 \times -1.0} = 0.9752 \quad (36)$$

Un decremento del 1.0 % en el oxígeno disuelto reduce las posibilidades en un 2.48 %. La probabilidad disminuye de 88.95 % a 88.70 %, una variación de 0.25 puntos porcentuales.

Cuadro 16: Cálculo de variaciones en el cociente de posibilidades - Lénticos

Variable ($\hat{\beta}$)	Variación (ΔX)	Cociente ($e^{\beta\Delta X}$)	Impacto en el Riesgo	Probabilidad
Dureza Transformada (6,3856)	+1,0 unid.	593,08	+59,208 %	99,98 %
	-1,0 unid.	0,00169	-99,83 %	1,34 %
Temperatura (-0,4086)	+1,0 °C	0,664	-33,6 %	84,25 %
	-1,0 °C	1,505	+50,5 %	92,37 %
Oxígeno Disuelto (0,0251)	+1,0 %	1,0254	+2,54 %	89,19 %
	-1,0 %	0,9752	-2,48 %	88,70 %
Probabilidad base (valores medios): $P_0 = 88,95 \%$				

Nota metodológica. El análisis de sensibilidad de probabilidades se restringió a las tres variables continuas del modelo: Dureza Total Transformada, Temperatura del Agua y Oxígeno Disuelto. Las variables DBO_TOT y PB_TOT son dicotómicas (0/1) y, por tanto, no admiten variaciones marginales en escala continua; su efecto se interpreta exclusivamente mediante el cociente de posibilidades entre ambas categorías. Por otro lado, variables como pH o Conductividad, aunque continuas y disponibles en el conjunto de datos, no forman parte de la ecuación del modelo y carecen de coeficiente $\hat{\beta}$, lo que hace imposible cuantificar su impacto sobre la probabilidad estimada sin reestimar el modelo. En todos los escenarios las variables dicotómicas se fijaron en su media muestral, de modo que la probabilidad base ($P_0 = 88.95 \%$) refleja las condiciones promedio del conjunto de entrenamiento.

3. Conclusión

El modelo que fue seleccionado y denominado como óptimo para ambos tipos de cuerpos de agua fue el Modelo AIC con transformación de Box-Tidwell. En el caso de cuerpos lóticos, el modelo AIC registró $AIC = 278.46$ y $BIC = 308.82$, valores menores a los resultantes en el modelo BIC; en el caso de los cuerpo lénticos, obtuvo $AIC = 167.23$ comparado con el modelo BIC, mientras se conserva el mejor Pseudo- R^2 en todas las métricas evaluadas.

Se justificó esta elección por el balance justo entre la capacidad predictiva y la parsimonia: el modelo lótico tiene un Nagelkerke de 0.556 (explica poco más de la mitad de la variabilidad del semáforo) con una exactitud de 83.13 %, que destaca por su especificidad del 100 % que respalda la ausencia de falsas alarmas de contaminación. Por su parte, el modelo léntico obtuvo un Nagelkerke de 0.3965, con valores de McFadden que se encuentran en un rango considera excelente para modelos de regresión logística. En los dos casos, todos los predictores superaron la verificación de no multicolinealidad.

El método stepwise bidireccional posibilitó la reducción de modelos iniciales de hasta 16 variables a 7 predictores en lóticos y 5 en lénticos, sin perder capacidad explicativa. Si el modelo lótico predice semáforo rojo, la probabilidad de que el sitio se encuentre realmente contaminado es del 100 %. De manera adicional, la imputación de datos KNN conservó la mayor cantidad de observaciones posibles sin agregar sesgo, y la

partición estratificada aseguró que las conclusiones no solamente fueran parte de la memoria del modelo, sino una herramientas de predicción real y aplicable a los datos.

Los dos modelos tienen una tendencia conservadora en su sensibilidad: 54.84 % en lóticos y 45.45 % en lénticos. Esto indica que aproximadamente la mitad de los sitios contaminados no son identificados de manera correcta, que indica una limitante en contextos de riesgo ambiental. Lo que se propone como mejora, es ajustar el umbral de clasificación por debajo de 0.5 para aumentar la sensibilidad, accediendo a tener un aumento pequeños de falsos positivos, o bien incrementar otro tipo de variables que influya en la identificación de cuerpos contaminados. De igual manera, el tamaño muestral de lénticos es menor al de lóticos, lo que ampliar la base de datos podría fortalecer la robustez del modelo.

El propósito del proyecto era crear una herramienta de predicción para reconocer cuerpos de agua en riesgo de incumplimiento normativo en Aguascalientes. Los modelos satisfacen de manera eficiente este problema, permitiendo que los encargados en el área se anticipen ante el estado del semáforo rojo a partir de señales químicas tempranas.

Para los cuerpos de agua lóticos, los principales factores de riesgo son la Absorción UV transformada y el Plomo Total. Para cuerpos lénticos, el factor que predomina es la Dureza Total transformada; a diferencia de la temperatura del agua, mientras disminuya la temperatura, aumenta el riesgo, lo que sugiere que las condiciones térmicas más frías están asociadas con un mayor incumplimiento normativo.

Sin embargo, los modelos finales ofrecen una respuesta más rigurosa estadísticamente: el riesgo hídrico está ligado a la presencia de metales pesados y carga orgánica, y la exclusión de E-COLI y DQO como predictores dejó obtener que la Absorción UV, Plomo Total y el Nitrógeno Total en lóticos, así como la Dureza Total y la Temperatura del Agua en lénticos, son los predictores de peso en el estado. Esto propone que el incumplimiento normativo tiene orígenes más complejos en parámetros fisicoquímicos que van variando según el tipo de ecosistema.

Referencias

- [1] Acosta Ramírez, C., & Lobo Laguado, S. M. (s. f.). *Evaluación de supuestos en regresión logística*. RPubS. Recuperado de https://rpubs.com/StephanyL/supuestos_regresion_logistica
- [2] Gujarati, D. N. (2010). *Econometría* (5. ed.). McGraw-Hill.
- [3] McFadden, D. (1974). Conditional logit analysis of qualitative choice behavior. En P. Zarembka (Ed.), *Frontiers in Economics*. Nueva York: Prensa Académica.
- [4] Montgomery, D. C. (2006). *Introducción al análisis de regresión lineal*. México: Limusa Wiley.
- [5] Nagelkerke, N. J. D. (1991). *A note on the general definition of the coefficient of determination*. *Biometrika*, 78(3), 691-692.